L’art brut en chiffres et en tableaux : quelle place pour l’image numérique et sa mesure en psychiatrie ?[1]

Matériel supplémentaire

Julie **Tang** (1), Parand **Danesh** (2), Anne-Marie **Dubois** (2), Nicolas **Garcelon** (3, 4), Olivier **Lienhard** (3, 4), Shahriar **Shandiz** (2), Raphaël **Gaillard** (1), Roman Hossein **Khonsari** (4, 5)

1. Pôle hospitalo-universitaire de santé mentale et de thérapeutique, Centre Hospitalier Sainte-Anne, GHU Paris Psychiatrie & Neurosciences, Paris
2. Musée d’Art et d’Histoire de l’Hôpital Sainte-Anne (MAHHSA), GHU Paris Psychiatrie & Neurosciences, Paris
3. Plateforme de sciences des données, Institut Imagine, Paris
4. AIDY, Institut Imagine, Paris
5. Laboratoire Forme et croissance du crâne, Institut Imagine, Paris

Ce document accompagne l’article ‘Humanités numériques et art brut : ce que la machine mesure dans le dessin’. La **partie I** présente le Data Challenge Outs[AI]der et les approches computationnelles applicables à un corpus d’œuvres réalisées en contexte clinique, à trois échelles (le pixel, l’image, la trajectoire), avec les figures S1 à S5 et le Tableau 1. La **partie II** est le répertoire détaillé des méthodes, classées en quatre familles (§ 1 à § 17), suivi d’une feuille de route opérationnelle (§ 18, Tableau 2) et de la bibliographie. Les renvois « § » de l’article correspondent à la numérotation de la partie II.

Partie I. Les approches computationnelles de l’art brut et le Data Challenge Outs[AI]der

I.1. Le Data Challenge Outs[AI]der : un cadre d’application des approches computationnelles à l’art brut

Comment affiner la description des caractéristiques formelles de l’image et constituer un vocabulaire de mesures suffisamment fin et reproductible pour entreprendre de le rattacher à des mécanismes cognitifs ? Le Data Challenge Outs[AI]der, qui sera lancé en automne 2027 s’inscrit dans cette perspective.[2] Il s’agit d’une compétition internationale en science des données organisée par le Groupe hospitalo-universitaire Paris Psychiatrie et Neurosciences (GHU) et l’hôpital Necker - Enfants malades, avec pour objectif d’identifier des caractéristiques formelles d’œuvres produites par des artistes-patients issues de la collection du

MAHHSA. Cette initiative vise, dans un second temps, à évaluer des liens entre travaux d'art-thérapie et troubles psychiatriques. Des équipes du monde entier seront mises en concurrence pour développer le modèle le plus performant dans la caractérisation formelle des œuvres d'art brut et l'établissement de liens avec des diagnostics psychiatriques. Cette compétition prend pour premier terrain d'expérimentation un vaste corpus numérisé issu des collections du MAHHSA, constitué d'œuvres produites dans des contextes psychiatriques et hospitaliers variés. L'objectif de la première étape d'Outs[AI]der est volontairement indépendant de toute hypothèse clinique, puisqu'il s'agit de développer et de comparer des méthodes capables de décrire de manière reproductible les caractéristiques formelles des œuvres, à savoir, entre autres, la composition, la densité, la couleur, la texture, l'organisation spatiale ou la récurrence de motifs, de façon à interroger les caractéristiques permettant de structurer et de comparer de larges ensembles d'images. Dans un second temps, les modèles pourront être appliqués à un corpus distinct de productions picturales associé à des données cliniques anonymisées, afin d'examiner l'existence éventuelle de relations entre certaines propriétés formelles et des variables cliniques. Cette architecture en deux temps permet de dissocier la caractérisation des œuvres de l'hypothèse selon laquelle les images contiendraient une signature visuelle de la pathologie. Dans ce contexte, nous proposons ici une analyse critique des différentes approches computationnelles développées à ce jour pour explorer la forme et la signification clinique des œuvres des artistes-patients, avec pour perspective leur mise à l'épreuve lors du déroulement du Data Challenge Outs[AI]der.

En 1999, Taylor et ses collègues appliquent dans une étude pionnière une approche computationnelle, l'analyse fractale, aux *drip paintings* de Pollock, puis aux ciels de Van Gogh.[3] Depuis cette date, ce champ d'investigations fournit une grande variété d'outils potentiellement utiles pour répondre aux différentes questions posées par Outs[AI]der : (1) Peut-on distinguer, à partir d'éléments formels seulement, les œuvres d'artistes-patients ou d'art brut d'un corpus d'œuvres dites conventionnelles ?, (2) Existe-t-il des caractéristiques formelles associées aux œuvres des artistes-patients ? et (3) Ces caractéristiques formelles, si elles existent, ont-elles une signification clinique ?

I.2. Classifier l'art brut : représentations apprises et comparaisons de corpus

Rapidement après leurs premières applications, les méthodes computationnelles ont servi à affiner l'attribution d'œuvres d'art, avec l'objectif de repérer des contrefaçons, une démarche qui s'apparente par son principe aux questions posées par Outs[AI]der (§11 à §14) : distinguer les dessins authentiques de Bruegel des imitations ; identifier les van Gogh autographes parmi les copies tardives ; segmenter trois cents dessins de Picasso, Matisse et Schiele en traits individuels pour montrer que le trait porte une signature personnelle presque impossible à imiter.[4] Dans ces approches, chaque œuvre prend position dans un espace de similarité construit sans a priori, permettant de quantifier sa distance avec le corpus considéré comme authentique. Dans le domaine de l'art brut, cette approche rencontre d'emblée un

obstacle : le corpus témoin peut contenir des œuvres d'artistes ayant présenté des troubles psychiatriques[5] tout comme un corpus de référence, même issu de musées prestigieux, peut contenir des 'faux'. Ce brouillage serait ici un biais conservateur, limitant la portée de l'étude par une absence de différence sans pouvoir fabriquer un écart.

Roberto, Ortego et Davis ont entraîné un réseau à distinguer des œuvres d'art brut d'œuvres conventionnelles issues de WikiArt (§12.5.2).[6] Leur résultat est encourageant : 84,3 % de précision en classification binaire. Plus intéressant encore, en classification multi-classe, l'art brut se positionne comme un vingt-septième style aux côtés du cubisme ou du surréalisme, avec une précision comparable. Les principales erreurs de classification se produisent avec le cubisme et l'expressionnisme, deux mouvements historiquement ouverts à son influence. Il est remarquable que ces proximités fassent écho à des circulations et filiations déjà documentées en histoire de l'art. Les méthodes employées par ces auteurs sont des méthodes de classification, qui permettent d'établir des différences de manière aveugle, sans que le vocabulaire visuel appris par les algorithmes ne soit interprétable cliniquement. Malgré le succès de leur approche, l'enjeu de l'étude structurelle de l'art brut reste majeur.

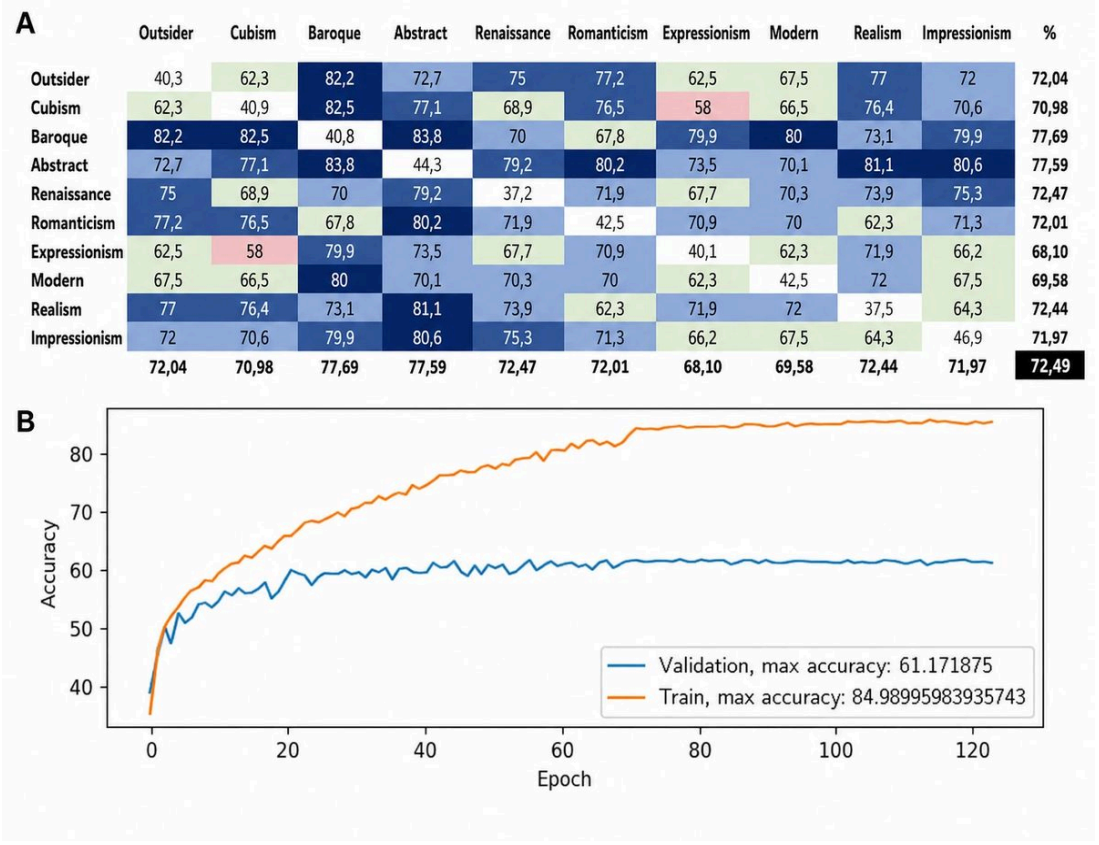


Figure S1. Classification de l'Outsider Art parmi les styles de WikiArt. Réseau ResNet-18 entraîné à situer l'Outsider Art parmi neuf styles canoniques de WikiArt. (A) Exactitude de la classification pour chaque paire de styles, en pourcentage ; hors diagonale, les valeurs les plus basses de la ligne « Outsider » sont obtenues avec le cubisme (62,3 %) et l'expressionnisme (62,5 %), les deux styles dont l'art brut se

distingue le moins bien, pour une exactitude moyenne de 72,49 %. (B) Exactitude en entraînement et en validation au fil des époques : le maximum atteint 85,0 % en entraînement contre 61,2 % en validation, écart qui signale un surapprentissage. D'après Roberto, Ortego & Davis (2020), figs. 5-6.

I.3. Quelles sont les caractéristiques formelles de l'art brut ? Quatre familles de méthodes

Groupe	Principes	Sections
A. Descripteurs explicites bas niveau	Mesures directes sur les pixels et leurs relations locales	§3 à §7
B. Mesures globales d'organisation	Quantification de la forme et des relations dans l'image	§8 à §10
C. Représentations apprises	Caractérisation de l'image par des modèles entraînés sur de grandes bases	§11 à §14
D. Approches temporelles et multimodales	Évolution dans le temps, intégration du texte et des métadonnées	§15 à §16

Tableau 1. Les quatre familles de méthodes computationnelles d'analyse d'images mobilisables pour l'étude d'un corpus d'art brut. Certaines approches relèvent de deux groupes ou plus. Le détail de chaque famille est donné dans la partie II ; la colonne « Sections » renvoie à sa numérotation.

I.4. À l'échelle du pixel : mesures locales et fréquentielles

Certains outils permettent de mesurer la matière du geste sans faire sens du sujet représenté, en quantifiant par exemple la pression, la répétition, la densité d'occupation, ou la régularité d'un hachurage (§3 à §6). Une image peut être décrite par la vitesse à laquelle ses valeurs varient dans l'espace - variations lentes pour un grand aplat, rapides pour des hachures fines, distinction ancrée dans la physiologie de la vision elle-même : le cortex visuel primaire code l'image selon des filtres sensibles à différentes échelles, classiquement décrits comme un gradient postéro-antérieur du plus concret au plus abstrait.[7] Son équivalent clinique immédiat se retrouve dans les grilles de cotation graphiques, dans la figure de Rey, ou encore dans les épreuves graphomotrices. De manière qualitative, dans ces approches, le clinicien note des caractéristiques telles que 'traits appuyés', 'remplissage compulsif', 'désorganisation du tracé' ; il est très probable que le descripteur produise une mesure correspondant aux mêmes perceptions cliniques.

Par exemple, dans l'une des rares études à confronter directement une mesure computationnelle à une catégorie clinique, Graham et Meng ont comparé des peintures de cinq artistes atteints de schizophrénie à un large corpus d'artistes sans diagnostic, et observé un contenu fréquentiel significativement différent.[8] Leur interprétation reste prudente (d'éventuelles altérations de la sensibilité au contraste) sans prétendre atteindre un diagnostic par l'image.

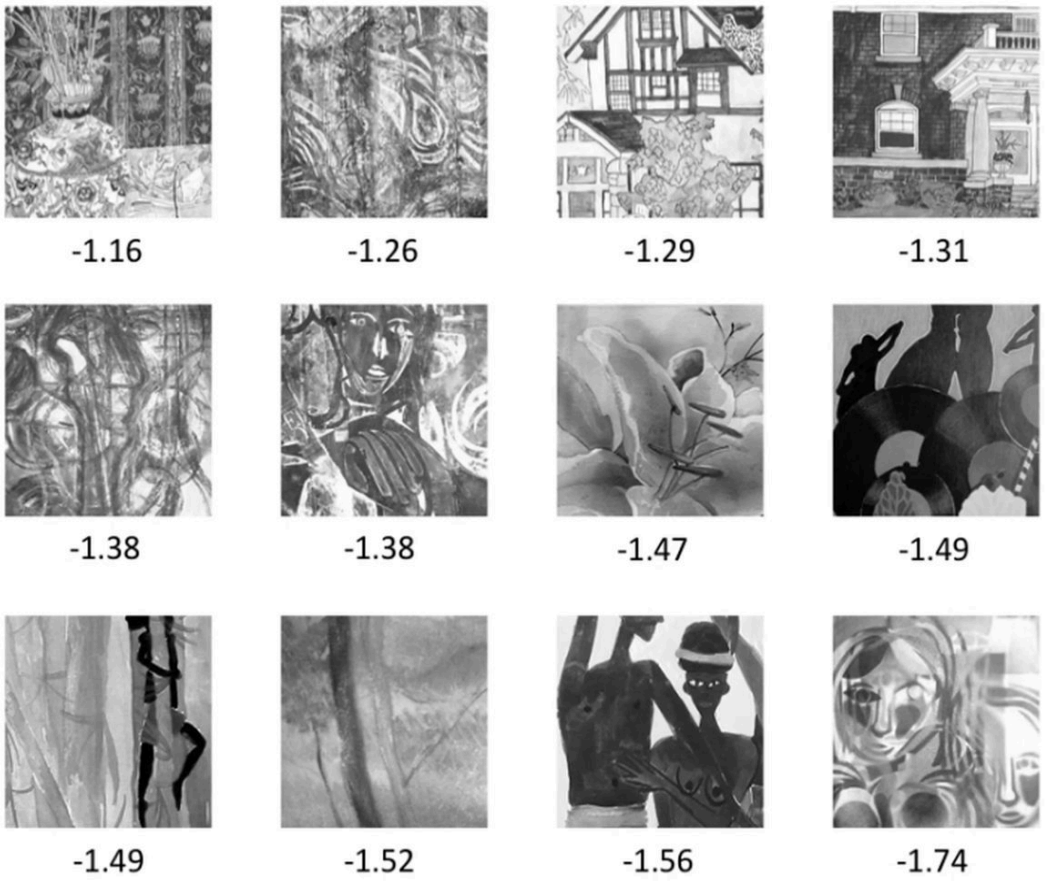


Figure S2. Détails de peintures ordonnés par la pente du spectre de Fourier. Douze détails de peintures présentés par pente décroissante du spectre de puissance de Fourier, dont la valeur est portée sous chaque vignette, de -1,16 à -1,74. La pente décrit la répartition de l'énergie entre basses et hautes fréquences spatiales, c'est-à-dire l'équilibre entre grandes masses et détails fins. Le contenu fréquentiel diffère significativement entre les peintures d'artistes atteints de schizophrénie ou de trouble schizo-affectif et celles d'artistes sans diagnostic. D'après Graham & Meng (2011).

I.5. À l'échelle de l'image : approches sémantiques et mesures globales d'organisation

Sigaki, Perc et Ribeiro ont placé près de cent quarante mille peintures dans un plan ordre-désordre / simplicité-complexité, à l'aide de deux descripteurs seulement (§8).[9] Ils y retrouvent les grandes transitions stylistiques de l'histoire de l'art - passage du figuratif à l'abstrait, ruptures du XXe siècle - sans aucune hypothèse préalable. Sans être totalement indépendantes des choix qui président à la constitution du corpus et à la sélection des descripteurs, ces mesures font apparaître des structures qui recoupent certaines périodisations établies, dans la même logique que les résultats obtenus par Roberto, Ortego et Davis[10] : un petit nombre de mesures statistiques peut faire émerger des regroupements compatibles (§14) avec des distinctions historiques et stylistiques établies de manière qualitative par les experts. Des notions psychanalytiques - l'horreur du vide, la prolifération ornementale, l'autonomisation du système formel décrite par Prinzhorn, la perte de la hiérarchie figure-fond - peuvent désormais être confrontées à des descriptions

formelles quantifiables (§7, §9, §10). Ces mesures rendent compte de l'architecture d'ensemble : le rapport entre le plein et le vide, la présence ou l'absence de hiérarchies, la répétition de motifs à différentes échelles.

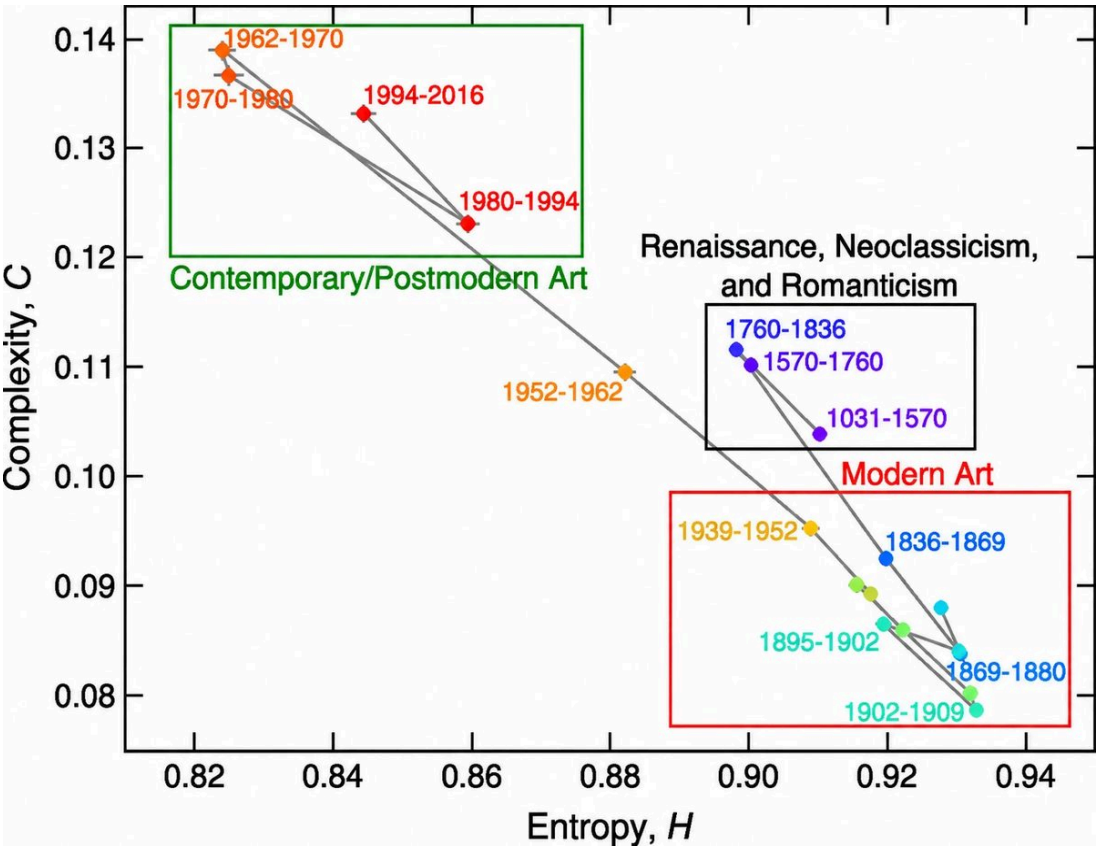


Figure S3. Cartographie de l'histoire de l'art dans le plan complexité-entropie. Position moyenne des grandes périodes de la peinture occidentale dans le plan entropie de permutation (H) / complexité statistique (C), calculée sur près de cent quarante mille œuvres et reliée par ordre chronologique. Trois ensembles se détachent sans hypothèse a priori : Renaissance, néoclassicisme et romantisme (1031-1836) ; art moderne (1836-1952) ; art contemporain et postmoderne (1962-2016). La trajectoire n'est pas monotone : la complexité baisse et l'entropie monte de la Renaissance à l'art moderne, puis le mouvement s'inverse au XXe siècle, l'art contemporain occupant la région de complexité élevée et d'entropie basse. D'après Sigaki, Perc & Ribeiro (2018).

En suivant une logique similaire, plusieurs travaux récents ont cherché à prédire les évaluations humaines de la créativité d'une œuvre, c'est-à-dire les scores donnés par des évaluateurs sur des dimensions comme l'originalité, la richesse imaginative ou la charge symbolique. Spee et al. (2023) ont montré, sur un corpus de peintures occidentales, que des dimensions sémantiques annotées par des humains (symbolisme, émotionnalité, imagination) prédisent ces évaluations mieux que les seules cartes de saillance (§7.4.4), ce qui souligne que les propriétés bas niveau ne suffisent pas à rendre compte du jugement esthétique (§16).[11] Ce travail souligne également une distinction importante : prédire une évaluation de la créativité ne revient pas à mesurer une propriété objective de l'œuvre appelée 'créativité'. Le modèle apprend à reproduire des jugements humains, eux-mêmes dépendants de

catégories et de conventions historiquement et culturellement situées. La quantification ne fait donc pas disparaître la part interprétative du jugement ; elle permet d'en formaliser certaines dimensions et d'en tester la reproductibilité. Des plateformes automatisées de notation de productions picturales sont par ailleurs apparues (AuDrA, OCSAI, CAP)[12], qui étendent ce type d'évaluation à grande échelle. Leur changement d'échelle ne doit cependant pas être confondu avec une objectivation de la créativité elle-même : il correspond avant tout à l'automatisation de critères d'évaluation préalablement définis ou appris à partir de la cognition humaine. Certaines équipes s'intéressent à décrire les processus cognitifs sous-tendant la pensée créative,[13] ouvrant de nouvelles perspectives quantitatives. Ces travaux sur la mesure de la créativité construisent des ponts solides avec les questions soulevées par les liens potentiels entre caractéristiques structurales de l'art brut et signification clinique.

Ainsi, Henemann, Brachmann et Redies ont analysé 1256 œuvres de quatorze artistes de la collection Prinzhorn, tous diagnostiqués à l'époque de *dementia praecox*, catégorie nosographique historique qui ne se superpose pas aux catégories diagnostiques contemporaines, en calculant six propriétés statistiques.[14] Leur conclusion est nuancée : ces œuvres ne se laissent pas réduire à un profil visuel simple ; certaines propriétés semblent générales, d'autres dépendent fortement de l'artiste plus que d'une symptomatologie. De plus, d'autres approches, comme celle de l'homologie persistante, suivent l'apparition et la disparition de structures (composantes isolées, boucles (§9.2)) selon la variation d'un seuil sur l'image (§9).

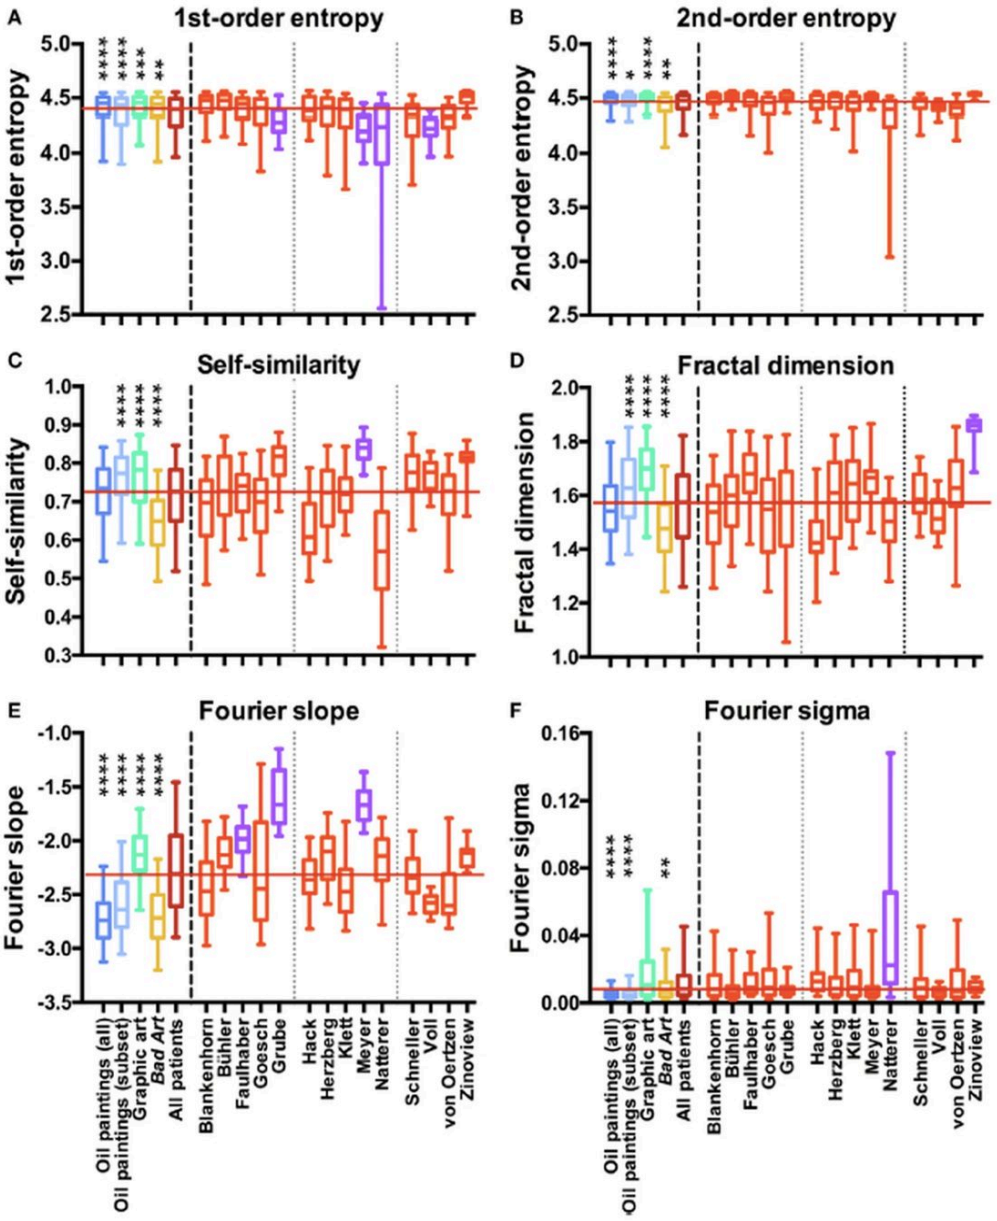


Figure S4. Propriétés statistiques d'œuvres de la collection Prinzhorn. Distributions de six descripteurs statistiques d'image calculées pour 1256 œuvres : (A) entropie d'ordre 1, (B) entropie d'ordre 2, (C) auto-similarité, (D) dimension fractale, (E) pente du spectre de Fourier, (F) paramètre σ du spectre de Fourier. À gauche du trait discontinu figurent les corpus de comparaison (peintures à l'huile, art graphique, 'Bad Art') et l'ensemble des artistes de la collection ; à droite, les quatorze artistes pris un à un. Le trait rouge marque la valeur médiane de l'ensemble des artistes, et les astérisques les corpus de comparaison qui s'en écartent significativement. Aucune propriété ne sépare la collection des corpus de comparaison de façon univoque : la variabilité tient d'abord à l'artiste. D'après Henemann, Brachmann & Redies (2017).

I.6. À l’échelle d’une trajectoire : approches longitudinales

Le suivi longitudinal est au cœur de la pratique psychiatrique : au bout d’un certain temps, chaque sujet devient son propre témoin, et les confusions liées à la formation artistique, à la culture ou au matériel disponible se neutralisent en partie. Il est possible de suivre dans le temps la palette, la densité, la composition, la complexité, ou mesurer la distance entre œuvres successives pour repérer ruptures brusques, dérives lentes et phases de stabilité (§15).

Les dernières années de Willem de Kooning ont ainsi été lues à travers un prisme neurologique en tentant de distinguer maladie, vieillissement, choix esthétiques, simplification volontaire, ou demandes du marché.[15] Une analyse longitudinale n’a de valeur qu’accompagnée d’une chronologie fiable et de données biographiques, afin de distinguer l’évolution de l’artiste de l’évolution de conditions matérielles et culturelles de son exercice. Cette nécessité souligne le rôle intriqué de l’établissement d’une histoire de cet art, d’un changement de médium imposé par l’institution, d’un changement de service, ou encore d’une modification du traitement. Dans le cas des collections d’œuvres d’artistes-patients au sein d’institutions psychiatriques, la trajectoire conservée ne se confond pas nécessairement avec la trajectoire de production. Les œuvres qui nous parviennent sont elles-mêmes le résultat de pratiques institutionnelles de sélection, de collecte, de classement et de conservation (§15.5). Une rupture observée dans une série peut ainsi témoigner d’une évolution de l’artiste, mais aussi d’une discontinuité dans la constitution de l’archive.

I.7. L’importance du regard clinique, historique et contextuel

En 2006, Jones-Smith et Mathur montrent que des griffonnages d’enfants présentent les mêmes propriétés quantitatives que des œuvres de Jackson Pollock, soulignant les limites de l’utilisation de descripteurs isolés (§5.3.4).[16] L’enjeu n’est pas d’opposer le calcul au regard de l’expert mais de construire les conditions d’une mise en relation optimale. Une variable computationnelle acquiert une signification lorsqu’elle peut être replacée dans une trajectoire documentée et, inversement, l’analyse computationnelle peut rendre visibles des régularités ou des ruptures que l’examen individuel des œuvres ne permettrait pas de percevoir à l’échelle d’un corpus, ou que les capacités de perception humaines ne capturent pas.



Figure S5. Alchemy, drip painting de Jackson Pollock (1947). Œuvre sur laquelle a été estimée par comptage de boîtes une dimension fractale d'environ 1,5. La portée de cette mesure a été discutée par la suite, des tracés sans rapport avec l'œuvre produisant la même valeur. D'après Taylor, Micolich & Jonas (1999).

I.8. L'analyse d'images en psychiatrie computationnelle : définir la question

Le défi majeur aujourd'hui est de définir le cadre opérationnel permettant de tester dans quelle mesure certaines propriétés formelles des productions picturales peuvent être associées à des informations documentées concernant leurs auteurs, sans présupposer la nature ni la causalité de cette association.

La psychiatrie computationnelle est traversée par plusieurs difficultés bien identifiées : une multiplication des programmes de recherche, peu de biomarqueurs robustes et une crise de réplication qui touche la psychiatrie biologique en général. De nombreux modèles fonctionnent bien sur leur échantillon d'entraînement et s'effondrent par ailleurs.[17]

Les limitations de ce domaine ne sont plus liées à la puissance des outils mais à la qualité de la problématique. Chercher à optimiser un diagnostic à partir d'un dessin présuppose que le dessin contient un diagnostic, ce qui pose une nouvelle fois une question datant de 1950, avec toutefois de meilleurs instruments de mesure. Une étude concluant que 'le corpus brut a une dimension fractale différente' serait techniquement vraie mais conceptuellement vide. Une différence statistique entre deux corpus renseigne d'abord sur ces corpus et sur les conditions de leur constitution. L'attribuer à une propriété de leurs auteurs suppose une chaîne d'inférences supplémentaire, qui doit elle-même être testée et mesurée.

Reste la distinction entre réduction ontologique et réduction méthodologique. La première postule que la souffrance psychique correspond aux données qui la décrivent - aliénation contre laquelle la clinique a raison de se prémunir. La seconde

utilise la quantification comme prisme heuristique, sans nier l'irréductibilité du vécu. Une clinique sans mesure reproductible condamne au particularisme, où chaque praticien impose une science incommunicable et incontestable. Une mesure peut être réfutée ; une intuition clinique opaque, beaucoup plus difficilement.

Partie II. Répertoire détaillé des méthodes d'analyse computationnelle

1. Du DAPA aux statistiques de l'image

1.1. Le DAPA, ou la dernière des approches pré-computationnelles

Le Descriptive Assessment for Psychiatric Art (Hacking, Foreman et Belcher, 1996 ; Hacking et Foreman, 2000) propose un protocole standardisé d'évaluation visuelle des peintures réalisées par des patients psychiatriques. L'observateur humain renseigne une série de paramètres descriptifs (proportion d'espace pictural occupée, surface colorée, intensité de pression du trait, présence ou non d'éléments figuratifs identifiables) selon une grille discrète. L'objectif est de produire des variables comparables entre patients et dans le temps, sans préjuger d'une signification clinique ni utiliser de traitement d'image au sens informatique.

1.2. Analyse quantitative de la collection Prinzhorn

Henemann, Brachmann et Redies (2017) ont analysé 1256 œuvres de quatorze artistes de la collection Prinzhorn, tous identifiés à l'époque comme atteints de dementia praecox, en calculant six propriétés statistiques précédemment validées pour la caractérisation d'œuvres d'art (entropie d'ordre 1 et d'ordre 2, auto-similarité, dimension fractale, pente du spectre de Fourier, paramètre σ d'orientation). Leur conclusion est nuancée (et limitée par la taille d'échantillon ndlr le nombre d'individus) : les œuvres de la collection Prinzhorn ne se laissent pas réduire à un profil visuel simple, certaines propriétés les rapprochent de l'art visuel général tandis que d'autres dépendent fortement de l'artiste et du sous-corpus (figure S4, partie I).

1.3. Perturbations quantitatives du dessin chez les schizophrènes

Graham et Meng (2011) ont comparé des peintures de cinq artistes atteints de schizophrènes ou de trouble schizo-affectifs à un large corpus d'artistes sans diagnostic, en utilisant l'analyse du spectre de Fourier. Ils ont observé un contenu fréquentiel significativement différent dans le groupe schizophrène. L'interprétation des auteurs est prudente, en lien avec d'éventuelles altérations de la sensibilité au contraste à basse fréquence, sans aucunement prétendre à un diagnostic par l'image (figure S2, partie I). Cette étude reste à ce jour l'une des rares à confronter directement une mesure computationnelle à un statut clinique défini, et fixe un principe : il est possible de produire un savoir computationnel sur la production plastique sans verser dans le diagnostic-par-l'image.

1.4. Cartographies stylistiques par théorie de l'information

Sur un registre méthodologique distinct, Sigaki, Perc et Ribeiro (2018) ont placé près de cent quarante mille peintures dans un espace ordre-désordre / simplicité-complexité, à l'aide de l'entropie de permutation et de la complexité statistique (cf. §8). Sans hypothèse clinique, ils retrouvent les grandes transitions stylistiques de l'histoire de l'art (passage du figuratif à l'abstrait, ruptures du XXe siècle) (figure S3, partie I). Cette étude illustre qu'un petit nombre de descripteurs statistiques bien choisis peut suffire à reconstruire des distinctions historiquement et perceptuellement pertinentes, et fonde l'usage descriptif non diagnostique des mesures d'information sur de grands corpus picturaux.

1.5. Premières utilisations de l'intelligence artificielle

Deux travaux publiés simultanément par Roberto, Ortego et Davis (2020) ont, à notre connaissance pour la première fois, entraîné un réseau de neurones convolutif (ResNet-18) à classifier des œuvres d'art brut en regard d'œuvres conventionnelles (issues de WikiArt). Sur la tâche binaire de classification, ces auteurs rapportent une précision de 84,3 %. Sur la tâche multi-classe (art brut positionné parmi vingt-six styles canoniques de WikiArt – cubisme, expressionnisme, surréalisme, baroque, romantisme entre autres), l'art brut se classifie avec une précision (≈72 %) comparable à celle des styles traditionnels. Ce résultat montre qu'un classifieur générique peut reconnaître l'art brut comme un style cohérent, ce qui suggère l'existence de régularités visuelles partageables ; d'autre part, la confusion la plus fréquente était observée avec le cubisme et l'expressionnisme, deux mouvements précisément ouverts à l'influence de l'art brut au XXe siècle. Roberto et Davis (2020) ont parallèlement proposé une ontologisation de l'art brut s'appuyant sur CIDOC-CRM[18] et les Getty Vocabularies, qui pose les bases méthodologiques d'une intégration des dimensions visuelles et sémantiques.

2. Quatre familles de méthodes computationnelles

Quatre groupes de méthodes computationnelles peuvent être définis en fonction de la donnée d'entrée et du traitement de l'information extraite des images source (Tableau 1, partie I).

Le Tableau 1 (partie I, § I.3) résume ces quatre familles ; certaines approches impliquent des techniques issues de deux groupes ou plus.

Famille A – Descripteurs explicites bas niveau

3. Analyse colorimétrique

3.1. Fondements

L'analyse colorimétrique extrait, à partir d'une œuvre numérisée, des paramètres décrivant l'usage de la couleur. Elle repose sur un fait physiologique : la vision humaine des couleurs est trichromate. Trois types de photorécepteurs rétiniens, les cônes, sont sensibles chacun à une bande de longueurs d'onde dominante : cônes L (Long), pic vers 564 nm, perçu rouge ; cônes M (Medium), pic vers 534 nm, perçu vert ; cônes S (Short), pic vers 420 nm, perçu bleu. La colorimétrie cherche à formaliser cette perception trichromate dans un espace de couleurs, c'est-à-dire un système de coordonnées dans lequel chaque couleur correspond à un point, et où l'on peut calculer une distance entre deux couleurs (Wyszecki et Stiles, 1982 ; Fairchild, 2013).

3.2. Trois espaces de couleur usuels

Le système RGB associe à chaque pixel trois nombres compris entre 0 et 255, correspondant aux intensités de rouge, vert et bleu. C'est le système utilisé par les écrans. Il est utile techniquement mais peu intuitif pour décrire la perception (Kim, Son et Jeong, 2014 ; Romero, Gómez-Robledo et Nieves, 2018).

Le système HSV (Hue, Saturation, Value), dérivé de RGB, sépare la teinte (la 'famille de couleur' : rouge, jaune, vert), la saturation (l'intensité apparente de la couleur, d'un gris terne à un coloris vif) et la valeur (la clarté, du noir au blanc). Il permet de distinguer, par exemple, une œuvre aux couleurs vives d'une œuvre aux couleurs éteintes même lorsqu'elles emploient des teintes proches (Smith, 1978 ; Nakauchi et Tamura, 2022).

Le système CIELAB, défini par la Commission Internationale de l'Éclairage (CIE, 1976) repose sur la définition d'un observateur standard (selon les principes établis par la CIE en 1931) et vise à rendre compte de la perception humaine. Chaque couleur est décrite par trois coordonnées : L* est la clarté perçue, du noir (L* = 0) au blanc (L* = 100) ; a* est la coordonnée sur un axe vert-rouge (négatif vers le vert, positif vers le rouge) ; b* est la coordonnée sur un axe bleu-jaune. Une propriété essentielle de CIELAB est sa quasi-uniformité perceptuelle : la distance euclidienne (ΔE) entre deux points de l'espace correspond, en première approximation, à la différence ressentie par un observateur humain (Sharma, Wu et Dalal, 2005).

L'espace CIE XYZ dont dérive CIELAB est l'espace de référence du CIE 1931 : la coordonnée Y représente la luminance perçue (la clarté), tandis que X et Z sont des combinaisons linéaires des sensibilités des trois cônes ne correspondant pas directement à une couleur perçue mais permettant de représenter toute couleur visible par un humain comme un mélange de trois primaires virtuelles à coefficients positifs (Wyszecki et Stiles, 1982).

3.3. Indices descriptifs

À partir de ces espaces, plusieurs indices peuvent être calculés : la teinte dominante et son écart-type ; la saturation moyenne ; la diversité chromatique (étendue effective des couleurs dans CIELAB, mesurée par le volume du nuage de points correspondant aux pixels) ; la clarté moyenne ; le contraste local ; et la distribution des couleurs (histogrammes de teinte). Une œuvre peut être très colorée mais peu diverse (mêmes teintes répétées) ou peu saturée mais très diverse (nombreuses nuances proches) (Kim, Son et Jeong, 2014 ; Nakauchi et Tamura, 2022 ; Romero et al., 2018).

3.4. Apports et limites pour l'étude de l'art brut

L'analyse colorimétrique permet d'objectiver des impressions formulées de manière qualitative ('palette resserrée', 'couleurs saturées', 'aspect monochrome', 'contraste brutal') et de produire des comparaisons statistiquement valides entre corpus. Sa principale limite tient à la chaîne de numérisation : la couleur mesurée sur un fichier numérique dépend de l'éclairage de la prise de vue, du capteur, de la balance des blancs, du vieillissement des pigments, du support et de la compression (Kim et al., 2014 ; Berns, 2019). Une étape de calibration colorimétrique, voire de comparaison sur des sous-corpus reproduits dans des conditions équivalentes, est indispensable pour appliquer les méthodes colorimétriques à l'étude d'un corpus d'art brut.

4. Analyse de fréquences spatiales

4.1. Définition d'une fréquence spatiale

Une image peut être décrite non plus par la valeur de chaque pixel, mais par la vitesse à laquelle ces valeurs varient dans l'espace. Les variations lentes (un grand aplat sombre, un dégradé progressif) sont dites basse fréquence ; les variations rapides (hachures fines, contours nets, granulation du papier) sont dites haute fréquence. Cette distinction est ancrée dans la physiologie visuelle : la rétine et le cortex visuel primaire codent l'image selon des bancs de filtres sensibles à différentes échelles spatiales (Campbell et Robson, 1968 ; De Valois et De Valois, 1990).

4.2. La transformée de Fourier

La transformée de Fourier est un outil mathématique qui permet d'écrire toute fonction (et donc toute image) comme une somme d'ondes simples (sinusoïdes) de différentes fréquences. Concrètement, on transforme une image (matrice de pixels) en une nouvelle matrice de la même taille, dans laquelle chaque case ne représente plus un point de l'espace, mais une fréquence spatiale (et une orientation). La valeur de chaque case mesure 'combien' cette fréquence est présente dans l'image. La transformée de Fourier est l'outil fondamental de l'analyse harmonique (Mallat, 2008 ; Bracewell, 1986).

Le spectre de puissance est la représentation de cette même information dans laquelle on ne retient, pour chaque fréquence, que l'intensité (l'énergie). Il permet de répondre à des questions du type : l'œuvre est-elle dominée par les grandes structures (basses fréquences) ou par les détails (hautes fréquences) ?

4.3. La loi en 1/f et son interprétation

Une observation centrale en statistiques de l'image naturelle est que pour la plupart des images photographiques du monde réel, le spectre de puissance décroît avec la fréquence selon une loi proche de $1/f^{\beta}$, avec β généralement compris entre 1,5 et 2,5. Lorsque $\beta = 2$, on parle de spectre 'en $1/f^2$' (Field, 1987 ; Ruderman, 1994 ; Tolhurst, Tadmor et Chao, 1992). Une telle loi signifie que l'image est statistiquement invariante par changement d'échelle : on retrouve la même structure de variations à toutes les tailles. Plusieurs études ont montré que les œuvres d'art, les cartoons, les comics et les mangas présentent une statistique en $1/f^2$ assez stable (Graham et Field, 2007 ; Koch, Denzler et Redies, 2010 ; Redies, Hasenstein et Denzler, 2007). La pente du spectre constitue donc un invariant : une pente plus marquée signale une image dominée par les grandes formes et pauvre en détails ; une pente plus faible signale une image très chargée en détails fins. Dans le domaine de l'art brut, cette mesure permettrait, par exemple, de tester l'idée intuitive selon laquelle de nombreuses œuvres brutes sont 'saturées de signes' : on attendrait alors une pente moins marquée que dans les corpus témoins.

4.4. Isotropie et anisotropie

L'isotropie désigne le fait qu'une propriété soit semblable dans toutes les directions. Une image isotrope présente une distribution équilibrée des orientations de ses contours ; une image anisotrope présente une direction dominante (verticales, horizontales, obliques). Les œuvres brutes très hachurées, écrites, ou organisées en grille peuvent présenter une anisotropie marquée, qui peut être quantifiée à partir du spectre de Fourier orienté ou par des bancs de filtres de Gabor (Koch et al., 2010 ; Henemann et al., 2017).

4.5. Ondelettes, filtres de Gabor et transformées de scattering

En effet, la transformée de Fourier classique fournit une description globale de l'image : elle indique quelles fréquences sont présentes mais pas où elles se trouvent. Pour des questions plus locales telles que 'Les hautes fréquences sont-elles concentrées dans une bordure écrite et dans un fond uni au centre, ou dispersées sur toute la surface ?' ou 'Les hachures sont-elles regroupées dans une zone précise ?' plusieurs familles d'outils, dites d'analyse multi-échelles, répondent à ce besoin.

4.5.1. Filtres de Gabor

Un filtre de Gabor est, mathématiquement, le produit d'une fonction sinusoïdale (qui sélectionne une fréquence et une orientation) et d'une fonction gaussienne (qui localise spatialement la mesure). Convoluer une image avec un banc de filtres de Gabor revient donc à demander, en chaque point : 'Y a-t-il, à cet endroit, des variations à la fréquence f et à l'orientation θ ?'. Les filtres de Gabor ont une correspondant en physiologie : Daugman (1985) a montré qu'ils modélisent les profils de réponse des neurones simples du cortex visuel primaire (V1). Ils sont depuis utilisés en analyse d'images comme descripteurs de texture orientée (Kim et al., 2014 ; Henemann et al., 2017).

4.5.2. Généralisation par ondelettes

Les ondelettes poussent cette logique plus loin. Une ondelette est une 'petite onde' localisée dans l'espace et dont la transformée de Fourier est elle-même localisée en fréquence. En dilatant l'ondelette (en l'étirant ou la rétrécissant) et en la translatant (en la déplaçant), on obtient un banc de filtres qui couvre toutes les positions et toutes les échelles de l'image. La transformée en ondelettes décompose donc l'image en une pyramide multi-résolution[19] (Mallat, 1989, 2008 ; Daubechies, 1992) (figure S1).

Figure S1. Décomposition multi-résolution d'une image par ondelettes. Décomposition pyramidale d'une image en ondelettes : à chaque niveau de résolution, une image d'approximation et trois bandes de détails (horizontale, verticale, diagonale) sont extraites, permettant une analyse simultanément localisée dans l'espace et en fréquence. D'après Mallat (1989), fig. 11.

L'intérêt pratique pour l'analyse d'œuvres a été démontré dans plusieurs travaux pionniers d'authentification. Lyu, Rockmore et Farid (2004) ont utilisé les moments statistiques[20] des coefficients d'ondelettes pour distinguer dessins authentiques et imitations de Pieter Bruegel l'Ancien, l'un des premiers succès méthodologiques de la statistique d'image appliquée à l'art. Johnson et al. (2008) ont coordonné une comparaison de plusieurs équipes utilisant des décompositions en ondelettes sur un même corpus de van Gogh, afin d'identifier les œuvres autographes et les copies tardives. Polatkan et al. (2009) ont étendu l'approche à la détection de faux par apprentissage supervisé sur descripteurs d'ondelettes.

4.5.3. Transformées de scattering

Les transformées de scattering (Mallat, 2012 ; Bruna et Mallat, 2013) sont une construction plus récente, conçue pour produire des descripteurs stables aux petites déformations géométriques et invariants par translation. Le résultat est mathématiquement proche de ce qu'apprennent les premières couches d'un réseau convolutif, mais sans paramètres à entraîner. C'est un atout majeur pour les corpus de taille limitée : un descripteur de scattering peut être calculé directement, sans entraînement préalable, et donne en pratique des performances comparables à un CNN sur de petits jeux de données. Cette propriété rend les transformées de

scattering pertinents pour les effectifs par artiste insuffisants pour entraîner un réseau profond. Ces transformées ont été appliquées avec succès à la classification de texture (Sifre et Mallat, 2013 ; Bruna et Mallat, 2013), à l'imagerie médicale (Andén et Mallat, 2014 ; Wiatowski et Bölcskei, 2018) et à la reconnaissance d'écritures historiques.

4.5.4. Pertinence pour l'étude de l'art brut

Les approches multi-échelles permettent de rendre compte de la présence de régimes graphiques différents à des endroits différents de l'œuvre (un centre dense, une bordure d'écriture, un fond hachuré). Dans les groupes où peu d'œuvres par artiste sont disponibles, les transformées de scattering offrent une alternative robuste aux embeddings profonds, sans nécessiter d'apprentissage. Leur limite tient au choix de l'ondelette mère (la forme élémentaire à partir de laquelle on construit toutes les autres par dilatation et translation) qui influe sur les résultats et doit faire l'objet d'une justification.

4.6. Limites générales de l'analyse fréquentielle

Les hautes fréquences sont mécaniquement accrues par la résolution de numérisation, le grain du papier, la présence d'écriture, les bordures et les compressions agressives. Toute comparaison fréquentielle doit donc être précédée d'une normalisation (cadrage, résolution, fond) et accompagnée d'une annotation de la présence d'écriture, de motifs répétitifs et de la texture du support. Ces précautions s'appliquent également aux ondelettes et aux transformées de scattering.

5. Texture, rugosité, fractalité

5.1. Qu'est-ce que la texture ?

La texture désigne la manière dont les petites variations de l'image se répètent localement, indépendamment de ce qu'elles représentent. Une photographie peut avoir la texture d'un tissu, d'une peau, d'un mur ; une œuvre peut avoir la texture de hachures, de points, de traits répétés, d'écritures serrées, ou des accidents matériels du support. La quantification de texture ne cherche pas à reconnaître un objet, mais à mesurer la régularité, la granularité, la densité et la répétition des éléments visuels (Haralick, Shanmugam et Dinstein, 1973 ; Tuceryan et Jain, 1993).

5.2. Outils classiques

Les matrices de cooccurrence de niveaux de gris (GLCM, Gray-Level Co-occurrence Matrix, Haralick et al., 1973) comptent combien de fois deux niveaux de gris donnés apparaissent côte à côte (à une distance et selon une orientation fixées) ; à partir de cette matrice, on calcule des indices d'homogénéité (à quel point les pixels voisins se ressemblent), de contraste local, d'énergie (concentration des cooccurrences sur quelques valeurs) et de corrélation (régularité directionnelle). Les filtres de Gabor

(Daugman, 1985) repèrent des motifs orientés à différentes échelles. Les motifs binaires locaux (Local Binary Patterns, LBP, Ojala, Pietikäinen et Mäenpää, 2002)[21] encodent chaque pixel par la comparaison à ses huit voisins, produisant des descripteurs de texture robustes aux variations d'éclairage. Les histogrammes de gradients orientés (HOG, Dalal et Triggs, 2005)[22] décrivent la distribution locale des directions des contours.

5.3. Auto-similarité, fractalité et multifractalité

5.3.1. L'auto-similarité comme propriété générique de l'art

Une image est dite auto-similaire lorsque l'on retrouve, à l'intérieur de l'image, des structures qui ressemblent statistiquement à l'image entière. Si l'on extrait une petite zone dans une œuvre, la distribution des contrastes, des orientations ou des couleurs y ressemble à celle de l'œuvre globale. L'auto-similarité peut être quantifiée par la mesure de distances entre histogrammes de descripteurs (par exemple, histogrammes de gradients orientés ou réponses à un banc de filtres) calculés à différentes échelles : si les histogrammes restent semblables d'une échelle l'autre, l'image est auto-similaire (Amirshahi et al., 2014 ; Redies, Hasenstein et Denzler, 2007). Redies et son équipe ont montré que cette propriété distingue les œuvres d'art esthétiquement valorisées d'autres types d'images (publicités, photographies non artistiques), et c'est l'un des six descripteurs centraux retenus par Henemann, Brachmann et Redies (2017) pour la collection Prinzhorn. L'auto-similarité est conceptuellement distincte de la fractalité (qui implique en outre une décroissance en loi de puissance des descripteurs) mais lui est étroitement apparentée.

5.3.2. Fractalité et dimension fractale

Une structure fractale est une structure dans laquelle des motifs semblables apparaissent à plusieurs échelles : la petite structure ressemble, statistiquement, à la grande structure (Mandelbrot, 1983).

La dimension fractale est une généralisation de la dimension géométrique usuelle : une ligne droite a une dimension 1, une surface une dimension 2 ; un objet fractal possède une dimension non entière, généralement comprise entre 1 et 2 pour une figure plane. La méthode la plus simple pour l'estimer est le box-counting : on recouvre l'image d'un quadrillage de mailles de plus en plus fines, on compte le nombre $N(\varepsilon)$ de mailles intersectant la forme à chaque résolution ε, et la dimension fractale D est définie par la pente de $\log N(\varepsilon)$ en fonction de $\log(1/\varepsilon)$. Plus D est grand, plus la forme remplit l'espace de manière complexe (Mandelbrot, 1983 ; Falconer, 2003).

5.3.3. Multifractalité : un objet, plusieurs dimensions

La dimension fractale est un nombre unique : elle suppose implicitement que la complexité de l'objet est la même partout. Or, dans les œuvres réelles, ce n'est presque jamais vrai. Certaines zones sont denses et chaotiques, d'autres sont lisses. Une description plus fine s'impose : la multifractalité.

Un objet multifractal est un objet dont les différentes parties présentent des comportements fractals différents. Plus précisément, on définit pour chaque exposant α (qui mesure la 'rugosité locale' en un point) la dimension fractale f(α) du sous-ensemble des points partageant cet exposant. La fonction f(α), appelée spectre multifractal, est l'identité multifractale de l'image. Une image monofractale a un spectre f(α) réduit à un point ; une image très hétérogène, dont les sous-régions ont des rugosités très différentes, a un spectre f(α) étalé. La profondeur multifractale, $\Delta D = D_0 - D\infty$, mesure cet étalement (Stanley et Meakin, 1988 ; Mureika, Cupchik et Dyer, 2005). Cette mesure capture mieux que la dimension fractale unique la signature stylistique d'un artiste, et Mureika et Taylor (2013) ont par exemple montré que les drip paintings de Pollock partagent une profondeur multifractale particulière avec les œuvres du mouvement québécois des Automatistes.

5.3.4 Fractalité des œuvres de Jackson Pollock

Taylor, Micolich et Jonas (1999) avaient initialement proposé que les drip paintings de Pollock présentent une signature fractale stable (figure S5, partie I) ($D \approx 1{,}7$) susceptible d'authentifier ses œuvres. Ces résultats ont été contestés : Jones-Smith et Mathur (2006) ont montré que de simples griffonnages d'enfants pouvaient reproduire les mêmes propriétés fractales, et que la fenêtre d'échelles disponible sur une peinture (typiquement deux à trois ordres de grandeur) était trop étroite pour établir une loi de puissance au sens strict. L'introduction de mesures multifractales par Mureika et collaborateurs a partiellement répondu à ces critiques, en montrant que la profondeur multifractale discrimine mieux les styles que la dimension fractale simple, mais ne suffit pas non plus à authentifier (Mureika et Taylor, 2013).

Un descripteur statistique seul ne suffit jamais à conclure ; il doit être inscrit dans un protocole de validation incluant des contrôles, des corpus de référence et une analyse critique des conditions d'acquisition (Mureika et Taylor, 2013 ; Smith et al., 2024 ; Ruiz de Miras et al., 2026).

5.4. Pertinence et limites pour l'étude de l'art brut

De nombreuses œuvres d'art brut semblent construites par accumulation de petits éléments (lettres, signes, yeux, figures répétées, hachures, cases). Les indices de texture, de rugosité et la dimension fractale offrent des outils pertinents pour quantifier cette logique d'accumulation. Une texture dense n'est pas en soi un signe pathologique : elle peut résulter d'une contrainte matérielle, d'une tradition décorative, d'un choix esthétique, d'un médium imposé ou d'un mode opératoire singulier (Henemann et al., 2017 ; Dubois, 2017).

6. Contours, lignes et gestes graphiques

6.1. Pourquoi un descripteur dédié au trait ?

Les descripteurs précédents traitent l'image comme une matrice de pixels, sans présupposer que cette image est dessinée. Or dans le dessin, la ligne est l'unité graphique fondamentale. Plusieurs travaux ont montré que le trait porte une signature individuelle particulièrement difficile à imiter, indépendante du sujet représenté (Hughes et al., 2010 ; Elgammal, Kang et den Leeuw, 2018 ; van Dantzig, 1973).

6.2. Détection de contours

La détection de contours transforme une image en une carte binaire de lignes. Les opérateurs classiques sont ceux de Sobel[23] (Sobel et Feldman, 1968), de Prewitt et surtout de Canny[24] (1986). Ces opérateurs sont utilisés en amont d'analyses morphologiques (longueur totale de trait, densité de contours par cm², courbure moyenne) et constituent l'étape préalable à toute analyse de stylométrie linéaire.

6.3. Segmentation et caractérisation des traits

Au-delà du contour pixel-par-pixel, plusieurs algorithmes segmentent un dessin en traits individuels : un trait est défini comme une courbe continue obtenue d'un mouvement de la main entre deux temps d'arrêt. Elgammal et al. (2018) ont proposé un algorithme dédié et l'ont appliqué à un corpus de trois cents dessins de Picasso, Matisse et Schiele ; à partir des traits ainsi isolés, ils calculent des descripteurs de longueur, courbure, vitesse apparente (estimée par la variation de pression et d'épaisseur), régularité et terminaisons. Ces descripteurs permettent une attribution automatique avec un haut degré d'exactitude, là où l'analyse globale échoue. Pour l'étude de l'art brut, ces outils peuvent aider à caractériser des traits hésitants, tremblés, répétés ou stéréotypés, des propriétés discutées en psychopathologie de l'expression mais rarement quantifiées (Volmat, 1956 ; Dubois, 2017).

6.4. Géométrie du geste

Une littérature parallèle, issue de la neurologie et de la rééducation, quantifie la qualité du geste par des invariants géométriques : courbure tridimensionnelle, jerk[25] (variation d'accélération), profils de vitesse (Osu et al., 2011 ; Flash et Hogan, 1985). Lorsque l'on dispose d'une numérisation à haute résolution, certains de ces invariants peuvent être estimés a posteriori à partir du trait laissé sur le papier, sans accès au geste lui-même. Cette piste est encore peu explorée pour des collections historiques mais ouverte par les travaux récents de stylométrie au niveau du trait.

7. Composition, Gestalt, saillance

7.1. L’organisation globale de l’image

Au-delà des descripteurs locaux (couleur, texture, contours), l’analyse de composition s’intéresse à l’organisation générale : qu’est-ce qui est au centre, qu’est-ce qui est en périphérie, qu’est-ce qui est isolé, qu’est-ce qui est groupé, qu’est-ce qui est vide, qu’est-ce qui est plein ? Ces questions ont été théorisées par la psychologie de la forme (Gestalt) au début du XXe siècle (Wertheimer, 1923 ; Koffka, 1935), reprises par Arnheim (1954) et formalisées récemment par Wagemans et al. (2012a, 2012b).

7.2. Figure/fond

Le rapport figure-fond désigne la capacité, pour un observateur, à distinguer un objet principal (la figure) d’un arrière-plan (le fond). Cette distinction perceptuelle, héritée de la psychologie de la forme (Rubin, 1915 ; Koffka, 1935), peut être plus ou moins claire selon les œuvres : fond saturé, figure noyée dans une texture, alternance possible des deux. Beaucoup d’œuvres d’art brut semblent perturber ces repères, ce qui justifie le recours à des descripteurs dédiés. Trois mesures sont couramment utilisées dans la littérature sur l’analyse computationnelle des images d’art (Aks et Sprott, 1996 ; Spehar et al., 2003 ; Brachmann et Redies, 2017). La proportion de surface non-fond correspond à la fraction de pixels appartenant aux objets segmentés (par seuillage automatique ou segmentation sémantique) plutôt qu’à l’arrière-plan ; elle quantifie le ‘taux de remplissage’ de l’œuvre. Le contraste figure-fond est la différence moyenne de luminance ou de couleur entre les pixels classés comme figure et ceux classés comme fond : un contraste élevé indique une figure nettement détachée, un contraste faible une œuvre où les frontières sont floues. La connexité du fond mesure si l’arrière-plan forme une région unique ou s’il est lui-même fragmenté – un fond fragmenté en de multiples îlots cessant fonctionnellement d’être un fond.

7.3. Saillance et modèles attentionnels

7.3.1. Le modèle d’Itti & Koch

La saillance visuelle est, en première approximation, ce qui attire spontanément l’attention : un contraste fort, une couleur vive, un visage, une forme isolée dans un champ régulier. Sa formalisation computationnelle remonte à Koch et Ullman (1985), dont la proposition d’architecture neuronale a été convertie en algorithme calculable sur n’importe quelle image par Itti, Koch et Niebur (1998 ; Itti et Koch, 2001). Dans leur modèle, l’image est décomposée en plusieurs cartes de caractéristiques (intensité, couleur, orientation), chacune calculée à plusieurs échelles à l’aide de filtres centre-périphérie (selon un mécanisme inspiré des champs récepteurs rétiniens). Ces cartes sont normalisées et combinées en une unique carte de saillance qui prédit, en chaque point, la probabilité que le regard d’un observateur

s’y porte (figure S2). Ce modèle, dit bottom-up (piloté par le stimulus, sans information sémantique), a inspiré toute une génération de recherches (Borji et Itti, 2013).

Figure S2. Architecture du modèle de saillance d’Itti, Koch & Niebur. L’image d’entrée est décomposée par filtrage linéaire en trois canaux élémentaires (couleurs, intensité, orientations) analysés à plusieurs échelles. Des différences centre-pourtour normalisées produisent respectivement 12, 6 et 24 cartes de caractéristiques, combinées inter-échelles en trois cartes de proéminence, puis en une carte de saillance unique. Un mécanisme de compétition (winner-take-all) en extrait le lieu regardé, l’inhibition de retour permettant le passage au suivant. D’après Itti, Koch & Niebur (1998).

7.3.2. Limites et extensions

Le modèle classique ne tient pas compte des informations sémantiques (un visage est saillant pour des raisons cognitives) ni des objectifs de la tâche (lire une légende, chercher un détail). Des modèles plus récents (DeepGaze II (Kümmerer, Wallis et Bethge, 2017) en particulier) combinent saillance bottom-up et information apprise, et améliorent la prédiction des fixations oculaires humaines. Ces modèles supposent toutefois la disponibilité de données d’oculométrie, ressource rare et coûteuse à acquérir : leur usage pour caractériser un corpus d’art brut reste donc principalement prospectif. Une utilisation plus accessible consiste à dériver de la carte de saillance des indices synthétiques (l’entropie de la carte (faible si l’attention est concentrée sur un point, élevée si elle est dispersée), le rayon de gyration des points saillants (étendue spatiale du regard prédit), ou la position du barycentre de la saillance) qui permettent une description statistique des compositions sans recourir à des fixations mesurées.

7.4. Organisation globale de l’image et propriétés statistiques d’ensemble

Au-delà de la saillance locale, l’analyse de l’organisation globale d’une œuvre (manière dont les éléments se distribuent, s’équilibrent, se répètent à l’échelle de la composition entière) fait l’objet d’une littérature plus directement utile à l’analyse d’œuvres patrimoniales, car elle ne suppose pas l’accès à des données oculométriques.

7.4.1. Équilibre, centralité, occupation

McManus, Stöver et Kim (2011) ont opérationnalisé la théorie arnheimienne de l’équilibre pictural en quantifiant, sur de larges corpus, la position du centre visuel (centre de gravité de la distribution d’intensité ou de saillance) par rapport au centre géométrique. Ils montrent que les compositions célèbres tendent à présenter un équilibre statistique entre quadrants. Des descripteurs simples mais informatifs en

sont dérivés : taux d'occupation (proportion de la feuille effectivement remplie), bordure investie vs. bordure vide, position du barycentre, moments d'ordre 2 de la distribution des intensités (variance horizontale et verticale).

7.4.2. Symétrie

La symétrie (variable diagnostique classique dans la tradition de la psychopathologie de l'expression) peut être quantifiée précisément par la corrélation entre l'image et son image-miroir, en variant l'axe (vertical, horizontal, oblique) pour identifier la symétrie dominante. Brielmann et Pelli (2018) montrent que la symétrie axiale verticale prédit une part substantielle des jugements de beauté, et cette propriété s'observe dès le très jeune âge.

7.4.3. Propriétés statistiques d'image et préférences esthétiques

Une famille d'études (Graham et Field, 2007 ; Redies, Hasenstein et Denzler, 2007 ; Brachmann et Redies, 2017) a mis en évidence que les œuvres d'art partagent des propriétés statistiques d'ensemble qui les distinguent des images naturelles et des images non-artistiques : pente du spectre de Fourier proche de 1/f β avec β plus stable que dans les photographies (cf. §4.3), auto-similarité accrue (cf. §5.3.1), distribution d'intensité approximativement normale, anisotropie réduite. Hayn-Leichsenring et al. (2017) montrent que ces propriétés sont associées à des évaluations esthétiques humaines.

7.4.4. Évaluations humaines de la créativité

Plusieurs travaux récents ont cherché à prédire les évaluations humaines de la créativité d'une œuvre, c'est-à-dire les scores donnés par des évaluateurs sur des dimensions comme 'originalité', 'richesse imaginative', 'charge symbolique'. Spee et al. (2023) ont montré, sur un corpus de peintures occidentales, que des dimensions sémantiques annotées par des humains (symbolisme, émotionnalité, imagination) prédisent ces évaluations mieux que les seules cartes de saillance, rappel que les propriétés bas niveau ne suffisent pas à rendre compte du jugement esthétique.

7.4.5. Apport pour l'étude de l'art brut

Les approches d'organisation globale sont, méthodologiquement, les plus immédiatement applicables à un corpus d'art brut : elles ne requièrent ni oculométrie, ni annotation sémantique fine, et fournissent des descripteurs interprétables (occupation, symétrie, équilibre, pente spectrale). Leur articulation avec une annotation experte du genre visuel (portrait, paysage, scène, page d'écriture) est indispensable, faute de quoi les différences mesurées refléteront essentiellement la distribution des genres et non des organisations compositionnelles distinctes.

Famille B – Mesures globales d'organisation

8. Entropie, complexité et théorie de l'information

8.1. Entropie de Shannon

L'entropie est un concept issu de la théorie de l'information (Shannon, 1948). Pour une variable aléatoire discrète X prenant les valeurs x1, x2, …, xn avec probabilités p(x1), p(x2), …, p(xn), l'entropie de Shannon est définie par $H(X) = -\Sigma\, p(xi) \log2\, p(xi)$. Concrètement, H mesure la quantité d'incertitude associée à X, ou de manière équivalente le nombre moyen de bits nécessaire pour coder un tirage de X. Pour une image, on peut calculer l'entropie de la distribution des niveaux de gris (entropie d'ordre 1) ou celle des couples de pixels voisins (entropie d'ordre 2^{26}). D'autres distributions peuvent être utilisées : distribution des gradients, des orientations locales, ou des ordres relatifs entre pixels voisins (cf. §8.3). Une image régulière, dans laquelle on peut prédire la valeur d'un pixel à partir de ses voisins, aura une entropie faible ; une image très variée aura une entropie élevée. Une entropie élevée n'implique cependant pas un désordre au sens psychiatrique ou esthétique du terme ; il s'agit d'une propriété strictement statistique.

8.2. Complexité statistique et entropie

L'entropie ne capture pas l'idée intuitive de complexité. Une image uniforme a une entropie nulle et n'est pas complexe ; mais une image entièrement aléatoire (un bruit blanc) a une entropie maximale tout en n'étant pas complexe au sens informationnel car elle n'a pas de structure. Les images les plus complexes sont celles qui présentent à la fois de la variété et de la régularité (Crutchfield, 2012 ; Sigaki et al., 2018).

Plusieurs mesures formalisent cette intuition. La complexité statistique au sens de Rosso et al. (2007) combine l'entropie de permutation et la distance de Jensen-Shannon[27] à la distribution uniforme. Elle est définie par $C = H \times D$, où H est l'entropie de permutation normalisée (entre 0 et 1) et D est la distance de Jensen-Shannon à la distribution uniforme (également entre 0 et 1). Une image uniforme a $C = 0$ parce que H est nul ; une image aléatoire a aussi $C = 0$ parce que D est nul (sa distribution est proche de la distribution uniforme) ; et seules les images structurées (ni totalement régulières, ni totalement aléatoires) atteignent des valeurs élevées de C. Cette mesure a été appliquée à 137 000 peintures par Sigaki, Perc et Ribeiro (2018), qui ont retrouvé les grandes périodes stylistiques de l'histoire de l'art dans un plan complexité-entropie.

8.3. Entropie de permutation, en termes simples

L'entropie de permutation (Bandt et Pompe, 2002) repose sur une idée simple : décrire chaque petite zone de l'image non par les valeurs d'intensité de ses pixels, mais par leur ordre relatif. Pour une fenêtre glissante contenant trois pixels (gauche,

centre, droite), on note simplement quel pixel a la plus grande valeur d'intensité, quel pixel a la plus petite, et quel est le rang du troisième. Cela donne six classements possibles (3! = 6). On parcourt l'ensemble de l'image en faisant glisser la fenêtre, on compte la fréquence d'apparition de chacun des six ordres, et on calcule l'entropie de Shannon de cette distribution. Cette mesure a l'avantage de ne dépendre ni du contraste global de l'image, ni d'une éventuelle transformation monotone des valeurs des pixels (changement d'éclairage, correction gamma), et de rester stable en présence de bruit modéré, parce que ces transformations préservent l'ordre relatif des intensités (Sigaki et al., 2018).

8.4. Compressibilité

Si une image peut être fortement compressée sans perdre beaucoup d'information (par exemple, par un algorithme générique comme PNG, JPEG-2000 ou ZIP), c'est qu'elle contient beaucoup de régularités. Si elle se compresse mal, c'est qu'elle contient beaucoup de variations difficiles à résumer. Cette idée trouve une formalisation théorique dans la complexité de Kolmogorov (Kolmogorov, 1965 ; Li et Vitányi, 2008), définie comme la longueur du plus court algorithme informatique[28] capable de reconstruire l'image, c'est-à-dire de la régénérer pixel par pixel à partir de zéro. La complexité de Kolmogorov n'est pas calculable en général, mais elle peut être approchée par des algorithmes de compression. Cette approximation est sensible à la résolution, au bruit et à la numérisation, et doit être interprétée avec prudence.

8.5. Apports et limites pour l'art brut

Les indices entropiques et de complexité permettent de placer chaque œuvre dans un plan ordre-désordre / simplicité-complexité, et donc de comparer des corpus de manière synthétique. Pour l'étude d'un corpus d'art brut, ces indices répondent partiellement aux trois objectifs définis en introduction : ils fournissent un indicateur global de différenciation entre corpus brut et corpus conventionnel (Comparer), permettent de positionner les œuvres dans un espace continu pour décrire les régimes visuels du corpus brut (Caractériser), et offrent des variables continues exploitables pour rechercher des corrélations avec les données cliniques disponibles (Corréler). Ces mesures sont toutefois abstraites : une œuvre à haute entropie peut être saturée de signes, riche en couleurs, pleine de texte ou simplement mal numérisée. Elles doivent toujours être couplées à des annotations explicites (densité, présence de texte, remplissage, symétrie) pour devenir interprétables (Lee et al., 2020 ; Sigaki et al., 2018).

9. Analyse topologique et homologie persistante

9.1. Que mesure la topologie ?

La topologie étudie les propriétés d'un objet qui se conservent par déformation continue : nombre de composantes connexes, nombre de trous, nombre de cavités. Une tasse à café et un donut sont topologiquement équivalents (chacun a un trou, celui de l'anse pour la tasse, celui central pour le donut) ; une boule et un cube sont topologiquement équivalents (aucun trou). Ces invariants sont robustes au bruit et aux petites variations métriques, ce qui en fait des descripteurs intéressants pour l'analyse de l'image (Edelsbrunner et Harer, 2010 ; Carlsson, 2009).

9.2. Homologie persistante : suivre les structures à toutes les échelles

L'homologie persistante étend cette idée à une analyse multi-échelle. Pour une image en niveaux de gris, on construit une famille emboîtée d'ensembles : ε étant un seuil croissant, on garde les pixels d'intensité inférieure à ε (filtration en sur-niveaux). Au début (ε petit), peu de pixels sont retenus, il y a peu de composantes connexes ; à mesure que ε augmente, des composantes apparaissent (birth), fusionnent ou disparaissent (death). On enregistre, pour chaque composante connexe ou chaque trou, le couple (birth, death)[29]. L'écart death – birth est la persistance de la structure : une structure très persistante existe sur une large plage d'échelles et correspond à une organisation forte de l'image ; une structure peu persistante est, en général, du bruit (Edelsbrunner et Harer, 2010 ; Otter et al., 2017).

9.3. Représentations et applications

L'ensemble des couples (birth, death) constitue un diagramme de persistance. Il peut être vectorisé sous forme d'images de persistance (Adams et al., 2017) ou de paysages de persistance[30] (Bubenik, 2015), qui s'intègrent ensuite dans des approches d'apprentissage automatique. Dans le domaine de l'art, plusieurs travaux récents ont utilisé l'homologie persistante pour caractériser des styles picturaux (figure S3) (Asaad et Jassim, 2017 ; Don, Jurova et Skorobogatova, 2024 ; Munnangi et Giunti, 2025) ou pour relier la topologie de l'image à des réponses physiologiques d'observateurs (oculométrie, EEG). Dans le domaine de l'art brut, l'homologie persistante offre un descripteur particulièrement adapté aux œuvres construites par accumulation de petits éléments distincts (composantes connexes) ou par enchevêtrement (boucles, trous), deux régimes fréquents dans le corpus brut.

Figure S3. Homologie persistante appliquée à une œuvre picturale. Construction d'une filtration topologique sur une œuvre : à partir de l'œuvre (en haut à gauche) et de sa carte d'intensité (en haut à droite), l'image est binarisée pour une suite de seuils, (a) t = 100, (b) t = 150, (c) t = 200 ; les pixels se connectent en composantes puis en boucles, dont l'apparition (birth) et la disparition (death) le long du seuil

définissent l'homologie persistante. Les intervalles les plus longs caractérisent l'organisation visuelle propre à l'artiste. D'après Munnangi & Giunti (2025), figs. 2-3.

9.4. Avantages et limites

L'homologie persistante est robuste au bruit, invariante par rotation et translation et interprétable (les composantes et trous correspondent à des structures visuelles identifiables). Sa principale limite tient au coût calculatoire pour les grandes images, qui impose souvent un sous-échantillonnage, et à la difficulté d'intégrer plusieurs canaux de couleur (la littérature applique le plus souvent l'homologie persistante à des images en niveaux de gris ou à chaque canal séparément).

10. Analyse en graphes et réseaux

10.1. Pourquoi les graphes ?

Un graphe est un objet mathématique composé de nœuds (ou sommets) reliés par des arêtes (ou liens). Les graphes formalisent les relations : entre des éléments à l'intérieur d'un objet, ou entre des objets entre eux. En analyse d'art, deux usages distincts coexistent.

10.2. Graphes intra-œuvre : la structure relationnelle d'une image

Une image peut être représentée comme un graphe : les nœuds sont des éléments visuels (régions homogènes, taches colorées (blobs), visages détectés, patches d'image) et les arêtes encodent leurs relations (adjacence spatiale, similarité, encadrement). À partir de cette représentation, on peut calculer des mesures de réseau classiques : degré moyen (nombre de voisins par élément), coefficient de regroupement (les voisins d'un élément sont-ils voisins entre eux ?), centralité (quels sont les éléments les plus connectés au reste ?), longueur du chemin moyen, modularité[31] (l'image se décompose-t-elle en sous-groupes faiblement connectés ?). Ces mesures, importées de la théorie des réseaux (Newman, 2010 ; Barabási, 2016), offrent un vocabulaire pour décrire des organisations visuelles. Perc (2020) a appliqué ce vocabulaire à l'analyse esthétique. Vieira et al. (2015) construisent des graphes à partir de motifs détectés dans la peinture et montrent que les statistiques de réseau discriminent les styles aussi bien que les descripteurs de texture.

Pour l'étude de l'art brut, cette approche est adaptée aux œuvres construites par connexion d'éléments (figures encadrant d'autres figures, réseaux d'inscriptions reliées par des flèches, compartimentation en cases interconnectées) qui semblent être spécifiquement prévalentes.

10.3. Graphes inter-œuvres : cartographier les corpus

Un second usage consiste à construire un graphe dans lequel les nœuds sont les œuvres (ou les artistes, ou les collections) et les arêtes encodent des proximités visuelles (calculées à partir d'embeddings, voir §11) ou des relations contextuelles (collaborations, expositions communes, mentions documentaires). Ce graphe peut ensuite être analysé pour identifier des communautés (groupes d'œuvres densément reliées entre elles) à l'aide d'algorithmes comme la modularité de Louvain (Blondel et al., 2008). Schich et al. (2014) ont ainsi appliqué cette logique à 150 000 personnages historiques pour reconstituer une cartographie de la mobilité culturelle européenne (figure S4) ; Lee et al. (2020) ont utilisé une approche apparentée pour l'étude du paysage en peinture.

Figure S4. Cartographie réticulaire de la mobilité culturelle européenne. Trajectoires de personnages historiques reconstruites à partir de bases biographiques, chaque individu reliant un lieu de naissance à un lieu de décès. (A) Nombre d'individus vivants par année depuis l'an 1, comparé à la population mondiale ; (B) Distribution des âges de 1500 à 2000 ; (C) Lieux classés en sources de naissance (bleu) et attracteurs de décès (rouge) ; (D) Réseau des flux entre villes ; (E) Report géographique sur l'Europe, où Paris, Londres, Rome, Berlin, Munich et Vienne se détachent comme attracteurs persistants. D'après Schich et al. (2014).

10.4. Graph Neural Networks (GNN)

Les réseaux de neurones sur graphes (GNN : Kipf et Welling, 2017 ; Veličković et al., 2018)[32] généralisent les CNN aux données structurées en graphes. Chaque nœud échange itérativement des informations avec ses voisins, ce qui permet d'apprendre des représentations qui tiennent compte de la structure relationnelle. Les GNN sont utilisés en analyse d'art pour combiner embeddings d'image et information contextuelle (cartels et autres métadonnées), et pour classifier ou recommander des œuvres dans des bases volumineuses. Garcia, Renoust et Nakashima (2020) ont par exemple appliqué les GNN à la base SemArt pour combiner image et commentaires textuels.

10.5. Apports et limites pour l'étude de l'art brut

L'analyse en graphes offre un cadre unifié pour penser à la fois la structure interne des œuvres et leur position dans un réseau d'œuvres comparables. Sa principale limite est sa dépendance à la construction du graphe : changer la métrique de similarité, le seuil de connexion ou la définition des nœuds modifie significativement les résultats.

Famille C – Représentations apprises

11. Stylométrie, codage parcimonieux et signatures stylistiques

11.1. Qu’est-ce qu’un style ?

Le style ne désigne pas le sujet représenté mais la manière de le représenter : type de trait, rythme des contours, texture, palette, organisation. La stylométrie visuelle cherche à mesurer ce style à partir de descripteurs quantitatifs, par analogie avec la stylométrie textuelle qui, depuis Mendenhall (1887), mesure le style d’un auteur à partir de la distribution des mots et de la longueur des phrases (Hughes et al., 2010 ; Elgammal et al., 2018 ; Vieira et al., 2015).

11.2. Codage parcimonieux

Le codage parcimonieux (sparse coding en anglais) (sparse coding, Olshausen et Field, 1996) repose sur l’idée qu’une image peut être reconstruite comme une combinaison linéaire d’éléments visuels de base (un dictionnaire) avec un petit nombre de coefficients non nuls. Si un dictionnaire est appris sur les œuvres d’un artiste donné, les éléments retenus reflètent sa grammaire visuelle. Hughes, Graham et Rockmore (2010) ont appliqué cette idée aux dessins de Pieter Bruegel l’Ancien (figure S5) : ils montrent qu’un dictionnaire parcimonieux permet de distinguer ses dessins authentiques d’œuvres attribuées à tort. Plus récemment, Elgammal et al. (2018) ont étendu cette logique au niveau du trait individuel pour Picasso, Matisse et Schiele.

Figure S5. Dictionnaire de caractéristiques visuelles appris par codage parcimonieux. Éléments de base appris sur les dessins authentiques de Pieter Bruegel l’Ancien : chacun code une orientation, une fréquence et une épaisseur de trait particulières, et tout dessin du corpus se reconstruit comme la combinaison de quelques-uns d’entre eux. La qualité de cette reconstruction fournit un critère d’attribution. D’après Hughes, Graham & Rockmore (2010).

11.3. Embeddings et représentations profondes

Une représentation vectorielle (embedding) d’une image est une liste de nombres (typiquement quelques centaines ou quelques milliers) qui résume certains aspects de l’image utiles pour des comparaisons. Au lieu de décrire explicitement chaque couleur ou chaque texture, on laisse un modèle d’apprentissage apprendre la représentation qui permet le mieux d’accomplir une tâche donnée (classification, recherche par similarité, mesure de distance stylistique). Deux images proches dans l’espace des embeddings sont considérées comme visuellement ou stylistiquement proches selon les critères appris par le modèle.

Les embeddings les plus utilisés en analyse d'images d'art sont : - les features extraites d'un réseau de neurones convolutif pré-entraîné (par exemple VGG ou ResNet, voir §12) ; - les embeddings produits par des modèles de fondation vision-langage (CLIP, DINO, voir §13) ; - les représentations issues de la matrice de Gram[33] des couches d'un CNN, popularisées par Gatys, Ecker et Bethge (2016) pour le transfert de style.

11.4. Transfert de style et matrice de Gram

Le transfert de style introduit par Gatys, Ecker et Bethge (2016) est une approche différente mais intéressante à détailler. Ces auteurs ont montré que, dans un réseau de neurones convolutif pré-entraîné, le contenu d'une image (‘ce qui est représenté’) et son style (‘la manière dont c'est représenté’) peuvent être séparés. Plus précisément, le style est capturé par la matrice de Gram des activations des couches intermédiaires : la matrice G dont l'élément G(i, j) est le produit scalaire entre les feature maps i et j à une couche donnée. Cette matrice encode quelles caractéristiques visuelles co-apparaissent en moyenne, sans tenir compte de leur position spatiale ; autrement dit, elle capture la texture et la grammaire visuelle sans le contenu. Deux images dont les matrices de Gram sont proches partagent un style ; deux images dont les activations spatiales sont proches (c'est-à-dire dont chaque région de l'image produit, dans les couches intermédiaires du réseau, des réponses comparables) partagent un contenu.

Pour l'analyse stylistique, cette construction offre un descripteur puissant et bien défini : la distance entre matrices de Gram peut être utilisée pour comparer des œuvres sans confondre style et sujet (Selim, Elgharib et Doyle, 2016 ; Bell et Ommer, 2019). Pour l'art brut, l'intérêt est précisément cette dissociation : on peut comparer le style d'un portrait à celui d'une scène, ou regrouper des œuvres représentant des sujets très différents mais traitées dans une grammaire visuelle commune (figure S6).

Figure S6. Séparation du contenu et du style par un réseau convolutif. (A) Photographie de contenu, le Neckarfront à Tübingen. (B) à (F) La même image resynthétisée en adoptant le style de cinq œuvres, reproduites en vignette : The Shipwreck of the Minotaur de Turner, La Nuit étoilée de Van Gogh, Le Cri de Munch, Femme nue assise de Picasso et Composition VII de Kandinsky. Le contenu est porté par les activations profondes du réseau, le style par les corrélations entre canaux d'une même couche (matrice de Gram). D'après Gatys, Ecker & Bethge (2016).

11.5. Apports et risques pour l'art brut

Les embeddings permettent une recherche par similarité particulièrement utile pour le travail muséal : un conservateur peut, à partir d'une œuvre, trouver les œuvres ‘voisines’ dans la collection selon différents critères. Mais cette proximité n'est pas nécessairement une proximité historique, biographique ou clinique : elle dépend du

modèle, de la base d'entraînement et de la tâche. Elgammal et al. (2018) ont montré que les cartographies produites par les modèles ne coïncident pas toujours avec les catégories des historiens de l'art, ce qui pourrait aboutir à des rapprochements inattendus entre art brut et d'autres courants par exemple.

12. Apprentissage profond supervisé : CNN, Transformers et limites

12.1. Principe général

L'apprentissage supervisé consiste à entraîner un modèle à prédire une étiquette connue (artiste, style, période, collection, art brut/non art brut, éventuellement diagnostic) à partir d'images. Le modèle ajuste progressivement ses paramètres pour réduire ses erreurs. La performance de cette approche dépend de la taille de la base, de la représentativité des exemples et de la possibilité d'éviter des raccourcis (le modèle apprend des artefacts non pertinents, comme le format de fichier ou la couleur du papier, plutôt que la propriété d'intérêt).

12.2. Réseaux de neurones convolutifs (CNN)

Un réseau de neurones convolutif (CNN) analyse l'image par petites fenêtres (les filtres convolutifs) qui détectent localement des motifs simples (contours, coins, textures). Les couches successives combinent ces motifs en représentations de plus en plus complexes : contours → formes → parties d'objets → objets → scènes. Cette architecture, popularisée par LeCun, Bengio et Hinton (2015) et appliquée à grande échelle par Krizhevsky, Sutskever et Hinton (2012) avec AlexNet, a dominé la vision par ordinateur pendant la décennie 2012-2020. Des architectures comme VGG (Simonyan et Zisserman, 2015), ResNet (He et al., 2016)[34] ou EfficientNet (Tan et Le, 2019) sont aujourd'hui largement utilisées comme extracteurs de features (cf. §11.3).

12.3. Vision Transformers

Le Vision Transformer (ViT, Dosovitskiy et al., 2021) propose une alternative : l'image est découpée en patches (petites zones de 16 × 16 pixels par exemple), et un mécanisme d'attention[35] (Vaswani et al., 2017) apprend les relations entre tous les patches, ce qui permet de mieux prendre en compte les organisations globales de l'image. Des variantes hybrides (Swin Transformer, ConvNeXt, Liu et al., 2021, 2022) combinent les forces des deux approches.

12.4. Transfer learning

Le transfer learning[36] consiste à réutiliser un modèle pré-entraîné sur un grand corpus (par exemple ImageNet[37], qui contient quatorze millions d'images d'objets photographiés) et à l'adapter à une tâche spécifique en n'ajustant qu'une partie des paramètres. Cette stratégie est cruciale pour les études en histoire de l'art, avec des

corpus souvent restreints. Elle est toutefois porteuse d'un biais : le modèle apporte avec lui les catégories visuelles apprises sur d'autres images, souvent photographiques, contemporaines et occidentales (Zhao et al., 2021 ; Cetinic, Lipic et Grgic, 2018).

12.5. Applications cliniques

12.5.1. Shen et al. (2021) : prédire des scores cliniques

Shen et al. (2021) ont entraîné un modèle profond sur des peintures réalisées par des patients atteints de schizophrénie chronique pour prédire certains scores symptomatiques. Le résultat est encourageant : certaines propriétés visuelles peuvent être corrélées à des dimensions cliniques. Ce résultat indique qu'à population, médium et conditions de production fixés, des signaux exploitables peuvent exister dans des œuvres graphiques avec une correspondance clinique.

12.5.2. Roberto, Ortego et Davis (2020) : classifier l'art brut

Les travaux de Roberto, Ortego et Davis (2020) sont les seuls à avoir explicitement entraîné un réseau de neurones convolutif à classifier l'art brut en regard d'un grand corpus d'art conventionnel. Le protocole utilise un ResNet-18 (He et al., 2016) pré-entraîné sur ImageNet et affiné en transfer learning sur deux jeux. Le corpus d'art brut rassemble des œuvres recueillies sur Internet à partir de sources documentant le domaine (catalogues, musées spécialisés). Le corpus comparatif d'art conventionnel est WikiArt, qui couvre l'histoire de l'art occidental sous une nomenclature de vingt-six styles. Deux expériences sont réalisées : binaire (art brut vs. WikiArt agrégé) et multi-classe (art brut comme vingt-septième style d'art conventionnel).

Les résultats principaux sont les suivants. (a) En classification binaire, le modèle atteint une précision de 84,3 %, ce qui indique qu'il existe un signal visuel statistiquement séparable entre les deux corpus. (b) En multi-classe, l'art brut se classifie avec une précision (≈72 %) du même ordre que les autres styles canoniques, ce qui suggère que la catégorie est, pour le réseau, aussi cohérente qu'un mouvement artistique reconnu. (c) Les confusions les plus fréquentes concernent le cubisme, l'expressionnisme et le surréalisme (figure S1, partie I), des mouvements précisément liés historiquement aux explorations de l'art brut par les avant-gardes du XXe siècle (Dubuffet, 1949 ; MacGregor, 1989).

12.5.3. Limites des résultats existants

Le corpus d'art brut de Roberto, Ortego et Davis (2020) a été constitué par recueil sur le web, sans contrôle des conditions de numérisation, ce qui expose à des artefacts d'acquisition (cf. §12.6). Le déséquilibre des effectifs entre art brut et corpus conventionnel impose une stratification rigoureuse. L'absence de métadonnées biographiques détaillées ne permet pas d'analyser les facteurs

explicatifs (artiste, période, médium, contexte de production). L'étude ne mobilise pas de méthode d'explicabilité, ce qui ne permet pas de vérifier sur quels signaux visuels la classification s'appuie.

12.6. Risques d'artefacts et méthodes d'explicabilité

12.6.1. Le piège des raccourcis

Plus un modèle est puissant, plus il peut apprendre des artefacts, c'est-à-dire des signaux qui distinguent les classes pour de mauvaises raisons : format de fichier, signature de scanner, type de papier, balance des blancs, compression, signature du photographe institutionnel. Plusieurs travaux ont documenté ce risque sous le terme d'apprentissage par raccourci (shortcut learning) (Lapuschkin et al., 2019 ; Geirhos et al., 2020) : un classifieur peut atteindre une excellente performance sur des données d'évaluation tout en s'appuyant sur des indices visuels sans aucun rapport avec la propriété d'intérêt.

12.6.2. Méthodes post-hoc d'explicabilité

Une famille de méthodes, dite post-hoc, cherche à expliquer après coup la décision d'un modèle entraîné. Trois approches sont devenues standards.

Les cartes de saillance par gradient (par exemple Grad-CAM ; Selvaraju et al., 2017) calculent quels pixels de l'image ont le plus contribué à la prédiction. L'idée intuitive est la suivante : si modifier légèrement la valeur d'un pixel modifie significativement la prédiction, ce pixel est important. Grad-CAM produit une carte de chaleur superposable à l'image originale (figure S7), qui permet de vérifier visuellement que le modèle s'appuie sur des régions porteuses de sens (le visage représenté, la texture du dessin) plutôt que sur des artefacts (le numéro de catalogue, le bord du papier).

LIME (Local Interpretable Model-agnostic Explanations ; Ribeiro, Singh et Guestrin, 2016) explique une prédiction donnée en construisant un modèle linéaire simple, valable localement autour de l'image étudiée. On perturbe systématiquement l'image (en masquant des zones), on observe les variations de prédiction, et on en déduit quelles zones expliquent localement la décision.

SHAP (SHapley Additive exPlanations ; Lundberg et Lee, 2017) attribue à chaque caractéristique d'entrée une valeur de Shapley[38] qui mesure sa contribution moyenne à la prédiction sur tous les sous-ensembles possibles d'autres caractéristiques. L'approche SHAP fournit des explications théoriquement solides mais coûteuses en calcul.

Figure S7. Cartes d'explicabilité d'un classificateur d'images. Sur une même photographie où figurent un chien et un chat, les régions ayant déterminé la décision du réseau sont localisées pour la classe ‘chat’ (a-f) puis pour la classe ‘chien’ (g-l), par rétropropagation guidée (b, h), Grad-CAM (c, i), Grad-CAM guidée (d, j), carte

d’occlusion (e, k) et Grad-CAM appliquée à un ResNet (f, l). Les zones chaudes désignent les régions les plus contributives, ce qui permet de vérifier si le modèle s’appuie sur des régions porteuses de sens ou sur des artefacts d’acquisition. D’après Selvaraju et al. (2017).

12.6.3. Limites des méthodes d’explicabilité

Adebayo et al. (2018) ont proposé des sanity checks sur les cartes de saillance et montré que certaines méthodes produisent des cartes apparemment plausibles même quand le modèle a été réinitialisé aléatoirement, ce qui invalide leur usage. Toute interprétation d’une carte de saillance doit donc être accompagnée d’une vérification : la carte change-t-elle quand on modifie l’image de manière contrôlée ? La carte distingue-t-elle un modèle entraîné d’un modèle aléatoire ?

12.6.4. Stratégies de robustesse complémentaires

Au-delà des méthodes d’explicabilité, plusieurs stratégies aident à limiter l’impact des artéfacts. L’augmentation de données[39] (variations de couleurs, recadrages, ajout de bruit) force le modèle à généraliser. La suppression contrôlée d’informations (occulter le cadre, normaliser la balance des blancs, sous-échantillonner pour égaliser les résolutions) permet de tester si la performance dépend d’éléments extérieurs à l’œuvre elle-même. Les tests d’attribution causale (contrefactuels : ‘si je change cet élément, la prédiction change-t-elle de la manière attendue ?’) renforcent la validation. Enfin, les tests adversariaux (Goodfellow, Shlens et Szegedy, 2015)[40] introduisent de petites perturbations imperceptibles à l’œil humain pour vérifier la stabilité de la prédiction.

12.6.5. Quelques recommandations pour l’application à l’art brut

Pour toute classification brut/non brut, les points suivants peuvent être considérés : (a) opérer une séparation par institution fournissant les œuvres d’art conventionnel ; (b) analyse Grad-CAM systématique sur les erreurs et sur les classifications correctes, pour vérifier que le modèle s’appuie sur des régions porteuses de sens ; (c) des tests de cohérence d’Adebayo ; (d) rénumérisation d’un sous-corpus dans des conditions équivalentes pour confirmation indépendante.

13. Auto-supervision et modèles de fondation

13.1. Au-delà du supervisé

L’apprentissage supervisé nécessite des étiquettes. Pour de nombreuses tâches en analyse d’œuvres d’art, ces étiquettes sont rares (par exemple le diagnostic d’un patient ayant produit une œuvre il y a un siècle) ou contestables (style, période). L’apprentissage auto-supervisé propose une voie alternative : le modèle apprend à reconstruire une image à partir d’une version dégradée, à associer deux vues d’une

même image, ou à prédire une partie de l'image à partir d'une autre, sans étiquette externe. Le modèle produit ainsi des représentations utiles pour des tâches diverses, sans s'engager sur une classification précise. Pour les trois objectifs définis en introduction, cette propriété est particulièrement intéressante : ces représentations permettent de séparer deux corpus dans un espace abstrait (Comparer), de cartographier la diversité interne d'un corpus brut sans hypothèse préalable sur ses catégories (Caractériser), et de fournir des descripteurs continus exploitables ultérieurement par des modèles supervisés légers entraînés sur les rares données cliniques disponibles (Corréler), évitant le sur-apprentissage qui résulterait d'un entraînement direct supervisé sur les œuvres elles-mêmes.

13.2. DINO et autres méthodes contrastives

DINO (Caron et al., 2021) est une famille de méthodes auto-supervisées qui apprend à produire la même représentation pour deux vues différentes d'une même image (recadrage, rotation, modification de couleur), ce qui force le modèle à extraire les invariants de l'image. DINOv2 (Oquab et al., 2024) constitue actuellement l'un des extracteurs de features les plus performants pour la transférabilité à des domaines nouveaux (art ancien, imagerie médicale, satellite). Pour le domaine de l'art brut, DINOv2 offre un excellent compromis : il fournit des embeddings de qualité sans nécessiter d'entraînement sur les œuvres elles-mêmes.

13.3. CLIP et alignement image-langage

CLIP (Radford et al., 2021) est un modèle entraîné sur quatre cents millions de couples image-texte issus du web à apprendre à projeter image et texte dans un espace commun où une image et sa légende sont proches. L'approche CLIP permet la classification zero-shot : on peut décrire une catégorie par une phrase ('un dessin d'une figure humaine au crayon') et demander au modèle de classer des images sans aucun exemple d'entraînement. Il permet aussi la recherche par concept ('montre-moi des œuvres qui contiennent un visage de profil avec des inscriptions'). Pour l'art brut, l'approche CLIP offre un outil d'exploration et d'annotation semi-automatique puissant.

13.4. Modèles génératifs et modèles de langage multimodaux

Une famille de modèles voisine, distincte par sa finalité (synthétiser des images plutôt qu'en classer) mais reposant sur les mêmes architectures profondes, comprend les modèles génératifs (GAN, diffusion models : Goodfellow et al., 2014 ; Rombach et al., 2022) et les grands modèles de langage multimodaux (GPT-4 avec vision, Gemini, Claude), capables de décrire une image en langage naturel. Ces modèles peuvent produire des descriptions iconographiques utiles, mais ils sont sujets à des hallucinations[41] : ils inventent parfois des éléments absents de l'image, en particulier pour des œuvres atypiques (Bender et al., 2021 ; Liu et al., 2024b). Leur usage en contexte clinique exige donc une validation systématique.

13.5. Pertinence pour l'art brut

Les modèles de fondation offrent trois avantages majeurs pour l'étude de l'art brut : ils ne nécessitent pas d'entraînement sur les œuvres, ce qui réduit le risque de sur-apprentissage ; ils sont robustes à des variations de domaine ; et ils permettent la recherche par concept, particulièrement utile pour des collections où les métadonnées sont hétérogènes. Leur principale limite est leur biais d'entraînement : ces modèles ont été entraînés sur des images du web, surreprésentant certains styles, certaines cultures et certaines périodes. Une œuvre d'art brut peut être mal représentée dans leur espace, ce qui peut produire des proximités trompeuses (Birhane, 2022).

14. Clustering non supervisé et cartographie des corpus

14.1. Principe

Le clustering consiste à regrouper des images sans étiquette préalable, simplement à partir de leurs représentations (descripteurs explicites ou embeddings). C'est une approche exploratoire : on ne cherche pas à confirmer une hypothèse mais à voir quelles familles émergent.

14.2. Méthodes usuelles

Le k-means (MacQueen, 1967)[42] regroupe les images autour d'un nombre fixé de centres, par minimisation itérative de la distance intra-groupe.

Le clustering hiérarchique (Ward, 1963) construit un arbre de proximités en agrégeant progressivement les plus proches.

HDBSCAN (Campello, Moulavi et Sander, 2013) cherche des groupes denses[43] sans imposer leur nombre, et identifie des points aberrants.

Les modèles de mélanges gaussiens offrent un cadre probabiliste qui associe à chaque point une probabilité d'appartenance à chaque groupe.

14.3. Projection et visualisation

Pour rendre les clusters interprétables, on projette les embeddings en deux dimensions. Les deux méthodes les plus utilisées sont t-SNE (van der Maaten et Hinton, 2008)[44] et UMAP (McInnes, Healy et Melville, 2018). Toutes deux préservent les voisinages locaux (figures S8 et S9) (deux points proches dans l'espace original restent proches dans la projection) mais déforment les distances globales. Une carte t-SNE/UMAP est donc une visualisation exploratoire et non une preuve de la structure du corpus.

Figure S8. Cartographie d’un corpus de peintures dans l’espace appris d’un réseau de neurones. Projection d’un corpus de peintures occidentales dans l’espace des représentations apprises par un réseau convolutif profond, chaque point étant coloré par la date de l’œuvre. (A) Les œuvres s’ordonnent spontanément selon une trajectoire proche de la chronologie de l’histoire de l’art, sans supervision temporelle ; les points extrêmes correspondent à des œuvres repères, de Raphael et Rembrandt aux avant-gardes du XXe siècle. (B, C) Les mêmes œuvres projetées sur des axes que les auteurs interprètent en termes de réalisme, d’abstraction et de popularité, où se séparent les grands mouvements. (D, E) Détail de deux régions de la carte. D’après Elgammal, Mazzone et al. (2018).

Figure S9. Effet de l’architecture et du pré-entraînement sur la carte obtenue. Projection du même corpus dans les deux premières composantes principales des représentations de plusieurs réseaux, chaque point coloré par la date de l’œuvre : (a, b) AlexNet+2 pré-entraîné puis affiné, puis entraîné depuis zéro ; (c, d) VGGNet+2 dans les deux mêmes conditions ; (e) ResNet+2 pré-entraîné puis affiné. Le tableau donne la corrélation de Pearson entre la date et chacune des deux composantes, ainsi que la distance radiale : l’ordonnancement chronologique se retrouve dans toutes les configurations, le plus nettement pour ResNet+2 (r = 0,77 sur la composante radiale). D’après Elgammal, Mazzone et al. (2018).

14.4. Apport pour l’art brut

Le clustering est une étape exploratoire intéressante : avant de chercher à classer brut/non brut, il est possible de demander aux algorithmes de clustering quels regroupements émergent spontanément. Les groupes correspondent-ils à des médiums (encre, peinture, crayon), à des périodes, à des artistes, à des thèmes, ou à des organisations graphiques transversales ? Cette question est compatible avec une démarche patrimoniale et clinique parce qu’elle ne présuppose pas que la catégorie diagnostique soit visible dans l’image (Lang et Ommer, 2021 ; Bell et Ommer, 2019).

14.5. Signification des clusters

Un cluster peut exister parce que les œuvres sont sur papier jauni, photographiées dans des conditions équivalentes, issues d’un même fonds, ou parce qu’elles partagent réellement une organisation visuelle. Un cluster sans interprétation peut correspondre à un artefact.

Famille D – Approches temporelles et multimodales

15. Analyse longitudinale intra-artiste

15.1. Pourquoi une approche longitudinale ?

La comparaison transversale (un patient vs. un témoin, un corpus vs. un autre) souffre d'un défaut majeur : la diversité interindividuelle est immense et masque presque toujours les effets cliniques. L'analyse longitudinale intra-artiste permet d'avancer dans la réponse à ce problème : au lieu de comparer des artistes différents, l'approche longitudinale consiste à suivre l'évolution d'un même artiste au cours du temps, en cherchant des ruptures internes. Les éléments mis en évidence de manière longitudinalte sont susceptibles d'être mis en regard de sa trajectoire psychopathologique (Piechowski-Jóźwiak et Bogousslavsky, 2018 ; Liu et al., 2018 ; Forsythe et al., 2017).

15.2. Mesures

À partir de descripteurs explicites ou d'embeddings, il est possible de suivre de nombreux paramètres dans le temps : la palette (couleur dominante, saturation, diversité), la densité, la composition, la texture, la complexité, la fréquence spatiale dominante, la présence de texte, la taille des figures. Il est également possible de calculer la distance entre œuvres successives dans l'espace d'embedding pour repérer des ruptures stylistiques (augmentation soudaine de la distance), des dérives progressives (évolution lente), ou des phases de stabilité.

15.3. Le cas de Kooning

Les œuvres des dernières années de Willem de Kooning, atteint de démence, ont été étudiées de manière transversale (Forsythe et al., 2017 ; Piechowski-Jóźwiak et Bogousslavsky, 2018). Les changements tardifs de style ont été interprétés à travers le prisme neurologique, mais il faut distinguer maladie, vieillissement, choix esthétique, simplification volontaire, ou encore demandes du marché. Une analyse longitudinale doit donc s'accompagner d'une chronologie fiable et de données biographiques.

15.4. Hot streaks et trajectoires créatives

Liu et al. (2018) ont introduit la notion de hot streaks, périodes de forte productivité ou de forte réussite dans les carrières artistiques, scientifiques et culturelles. Cette perspective est utile pour l'étude de l'art brut pour caractériser les phases de production d'un artiste en termes d'intensité, de ruptures et de reprises par exemple.

15.5. Conditions d’applicabilité

L’analyse longitudinale exige des métadonnées fiables : dates, supports, conditions de production. Dans un corpus hospitalier, il faut aussi pouvoir distinguer l’évolution de l’artiste de l’évolution des conditions matérielles et thérapeutiques (changement de médium imposé par l’institution, changement de service, modification du traitement). Sans cette stratification, les ruptures observées peuvent refléter le contexte plutôt que la personne.

16. Analyse sémantique, iconographique et multimodale

16.1. Au-delà des pixels

Les approches précédentes traitent l’image comme un signal. L’analyse sémantique cherche au contraire à identifier ce qui est représenté : personnages, animaux, objets, lieux, symboles, gestes, scènes. L’analyse iconographique interprète ces éléments dans un cadre culturel et historique (Panofsky, 1939). L’analyse multimodale combine l’image avec d’autres sources d’information : texte écrit dans l’œuvre, titre, métadonnées, notices de collection, archives biographiques, commentaires cliniques (Spee et al., 2023 ; Lang et Ommer, 2021).

16.2. Outils contemporains

Le captioning automatique produit une phrase descriptive (Vinyals et al., 2015 ; Li et al., 2022). La détection d’objets localise des éléments reconnaissables (Redmon et al., 2016 ; Carion et al., 2020). L’OCR reconnaît du texte imprimé ; la HTR (Handwritten Text Recognition) tente de lire de l’écriture manuscrite (Sánchez et al., 2019). Les modèles vision-langage (CLIP, BLIP, Flamingo : Radford et al., 2021 ; Alayrac et al., 2022) rapprochent image et concepts textuels dans un même espace.

16.3. Pertinence pour l’étude de l’art brut

Beaucoup d’œuvres d’art brut sont des systèmes mixtes image-texte : pages écrites, listes, alphabets inventés, inscriptions marginales, cartes, légendes. Un traitement purement visuel manque cette dimension. Une stratégie raisonnée pourrait distinguer au minimum : œuvres sans texte, œuvres avec texte lisible (en français ou autre), œuvres avec écriture illisible ou langue inventée, œuvres où le texte devient motif graphique. Cette stratification ouvre un champ de recherche spécifique sur les écritures asémantiques (Thévoz, 1979 ; Dubois, 2024).

16.4. Ontologies de l’Outsider Art

Une approche distincte mais convergente consiste à produire, en amont des analyses d’image, une ontologie du domaine étudié : un système formalisé de classes (œuvres, artistes, mouvements, médiums, contextes, collections), de propriétés (création, exposition, attribution, donation) et de relations entre elles. Roberto et Davis (2020),

dans un article jumeau de leur étude de classification CNN (cf. §1.4 et §12.5.2), proposent une ontologisation de l'art brut articulée à trois standards de référence en humanités numériques : CIDOC-CRM (norme ISO 21127 de modélisation du patrimoine culturel), l'Europeana Data Model (EDM, modèle d'agrégation des collections numériques européennes) et les Getty Vocabularies (vocabulaires contrôlés de l'histoire de l'art, dont l'Art & Architecture Thesaurus et l'Union List of Artist Names).

L'intérêt de cette démarche est triple. D'une part, elle permet d'examiner explicitement la question terminologique discutée en introduction et de désambiguïser les usages. D'autre part, elle ouvre la possibilité d'extraire automatiquement, par traitement automatique des langues[45], des relations à partir de biographies d'artistes, de notices de catalogue et d'archives cliniques. Enfin, elle permet de croiser les analyses visuelles avec les métadonnées structurées, condition pour des analyses multimodales.

Pour l'art brut, un étape importante serait d'aligner les nomenclature des différents corpus existants sur CIDOC-CRM et à enrichir progressivement, par TAL et annotation humaine, les liens entre œuvres, artistes, parcours et contexte clinique.

17. Méthodes cladistiques et reconstruction de filiations

17.1. La cladistique au-delà de la biologie

La cladistique, développée initialement par Hennig (1966) en biologie évolutive, est une méthode de reconstruction des relations entre objets (appliquée aux espèces vivantes) fondée sur le partage de caractères dérivés communs (synapomorphies[46]). Le principe est le suivant : on définit un ensemble de caractères discrets (présence/absence de telle structure, valeur de tel descripteur), on observe leur distribution dans une collection d'objets, et l'on construit l'arbre (le cladogramme) qui rend compte de ces distributions avec le minimum d'apparitions indépendantes du même caractère : c'est le principe de parcimonie. L'arbre obtenu n'est pas nécessairement temporellement orienté, mais il fournit une topologie de filiation exploitable.

Au-delà de la biologie, la cladistique a été appliquée à des objets culturels divers : langues (Bouckaert et al., 2012), traditions manuscrites (Robinson et O'Hara, 1996 ; Woerther et Khonsari, 2001 ; Howe et al., 2001 ; Windram et al., 2008), objets archéologiques (Tehrani et Collard, 2002), musique (Le Bomin et al., 2016). Dans le domaine textuel, Woerther et Khonsari (2001) ont notamment appliqué un programme phylogénétique informatique (PAUP)[47] à la tradition manuscrite de l'Ars Rhetorica du Pseudo-Denys d'Halicarnasse (figure S10), illustrant l'applicabilité opérationnelle de ces méthodes à des corpus historiques de complexité variable. Une revue synthétique des applications culturelles est proposée par Mace, Holden et Shennan (2005).

Figure S10. Stemma d’une tradition manuscrite reconstruit par méthode phylogénétique. Arbre cladistique de la tradition manuscrite de l’Ars Rhetorica du Pseudo-Denys d’Halicarnasse, obtenu par le programme PAUP appliqué à une matrice de variantes textuelles ; chaque terminaison porte le sigle d’un témoin (Par. 1656, Vat. 1405, Escorial, Guelf., entre autres), W occupant la position basale. La démarche est transposable à des corpus picturaux à condition de définir des caractères discrets analogues aux variantes manuscrites. D’après Woerther & Khonsari (2001).

17.2. Adaptation aux corpus picturaux

Adapter la cladistique à un corpus pictural suppose deux opérations préalables. Premièrement, choisir un ensemble de caractères discrets, suffisamment robustes pour être codés sans ambiguïté sur chaque œuvre : présence/absence de cadre, de signature, de visage humain, d’inscription, d’éléments répétés, choix de palette discrétisée, organisation compositionnelle (centrée vs. distribuée). Deuxièmement, définir une matrice de caractères œuvre × propriété, sur laquelle un algorithme de reconstruction (parcimonie maximale, Neighbor-Joining[48], méthodes bayésiennes) peut être appliqué pour produire un arbre ou un réseau. Le résultat est une arborescence de filiations stylistiques dont la structure peut être confrontée aux informations historiques disponibles (chronologie, biographie, institution).

17.3. Pertinence pour l’étude de l’art brut

Trois usages plausibles méritent une exploration prospective. Le premier est la reconstruction de l’évolution stylistique d’un même artiste : appliquée à un sous-corpus monographique, la cladistique pourrait dégager des étapes ordonnées de transformation du style sans présupposer une chronologie fixée. Le deuxième est l’identification d’un éventuel sous-groupe atypique au sein d’un corpus brut : si les œuvres d’un artiste constituent une branche nettement séparée du reste du corpus dans l’arbre cladistique, cette singularité topologique peut être mise en regard de la trajectoire clinique de l’artiste. Le troisième est la comparaison structurelle entre corpus : la topologie d’un arbre construit sur un corpus brut peut être comparée à celle d’un arbre construit sur un corpus conventionnel, pour évaluer si les structures de filiation diffèrent en degré de ramification, en équilibre, ou en présence de longues branches isolées.

17.4. Limites

La cladistique repose sur l’hypothèse biologique d’une transmission par filiation. Or, dans l’art, la transmission est souvent par influence, contamination, citation, copie partielle, ou par invariants iconographiques sans rapport généalogique. Les méthodes adaptées aux transmissions horizontales (réseaux phylogénétiques, split decomposition[49]) sont plus appropriées que les arbres stricts, comme l’a montré la littérature stemmatologique récente (Howe et al., 2001 ; Windram et al., 2008). Par ailleurs, le choix des caractères influence fortement le résultat : la robustesse d’une

reconstruction doit être évaluée par des tests de réplication (bootstrap[50], Felsenstein, 1985) et par comparaison à des reconstructions partielles obtenues sur des sous-ensembles de caractères. L'applicabilité de ces méthodes à l'art brut reste à explorer empiriquement et constitue à notre sens une piste exploratoire pertinente plutôt qu'une méthode immédiatement opérationnelle.

18. Synthèse opérationnelle pour une étude computationnelle de l'art brut

Une stratégie progressive et stratifiée

La stratégie la plus défendable scientifiquement combine deux principes : aller du plus interprétable au plus performant, et stratifier les comparaisons pour limiter le risque d'artefacts. Le Tableau 2 propose une feuille de route ordonnée par complexité croissante des tâches, du descriptif simple au prédictif clinique.

Tâche	Question posée	Approches recommandées	Risque principal
1. Décrire les corpus	Le corpus brut a-t-il des régimes visuels propres ?	Couleur, Fourier, texture, entropie, composition, organisation globale	Confusion avec médium et numérisation
2. Cartographier la diversité interne	Les œuvres se regroupent-elles en familles visuelles ?	Embeddings DINOv2 ou CLIP + UMAP + HDBSCAN	Familles non signifiantes sans expertise
3. Intégrer texte et image	Comment exploiter conjointement les écritures, titres, métadonnées et l'image ?	OCR/HTR + modèles vision-langage + annotation iconographique	Risque d'interprétation forcée
4. Discriminer brut et non brut	Un modèle distingue-t-il les deux corpus ?	CNN/ViT supervisés avec splits par institution + Grad-CAM	Artefacts de collection
5. Reconstruire des filiations	Peut-on dégager des arbres ou des réseaux de proximité entre œuvres ou entre artistes ?	Graphes, réseaux phylogénétiques, méthodes cladistiques	Choix des caractères, transmissions horizontales
6. Suivre une trajectoire individuelle	Observe-t-on des évolutions ou ruptures intra-artiste ?	Analyse longitudinale sur descripteurs et embeddings	Besoin de chronologie fiable
7. Relier image et clinique	Existe-t-il un lien entre des propriétés visuelles et des paramètres cliniques ?	Modèles supervisés sur sous-corpus documentés cliniquement, avec validation externe	Réduction de l'œuvre au symptôme

Tableau 2. Feuille de route opérationnelle pour une étude computationnelle d'un corpus d'art brut, ordonnée par complexité croissante des tâches, du descriptif (tâche 1) au prédictif clinique (tâche 7). Chaque tâche est associée à un ensemble de méthodes prioritaires et à son risque méthodologique principal.

Bibliographie

Adams, H., Emerson, T., Kirby, M., Neville, R., Peterson, C., Shipman, P., Chepushtanova, S., Hanson, E., Motta, F. & Ziegelmeier, L. (2017). Persistence images: A stable vector representation of persistent homology. Journal of Machine Learning Research, 18, 1–35.

Adebayo, J., Gilmer, J., Muelly, M., Goodfellow, I., Hardt, M. & Kim, B. (2018). Sanity checks for saliency maps. Advances in Neural Information Processing Systems, 31.

Aks, D. J. & Sprott, J. C. (1996). Quantifying aesthetic preference for chaotic patterns. Empirical Studies of the Arts, 14(1), 1–16.

Alayrac, J.-B., Donahue, J., Luc, P., Miech, A., Barr, I., Hasson, Y., Lenc, K. et al. (2022). Flamingo: A visual language model for few-shot learning. Advances in Neural Information Processing Systems, 35, 23716–23736.

Amirshahi, S. A., Hayn-Leichsenring, G. U., Denzler, J. & Redies, C. (2014). JenAesthetics subjective dataset: Analyzing paintings by subjective scores. In European Conference on Computer Vision Workshops (pp. 3–19). Springer.

Andén, J. & Mallat, S. (2014). Deep scattering spectrum. IEEE Transactions on Signal Processing, 62(16), 4114–4128.

Aragón, J. L., Naumis, G. G., Bai, M., Torres, M. & Maini, P. K. (2008). Turbulent luminance in impassioned van Gogh paintings. Journal of Mathematical Imaging and Vision, 30, 275–283.

Arnheim, R. (1954). Art and Visual Perception: A Psychology of the Creative Eye. University of California Press.

Asaad, A. & Jassim, S. (2017). Topological data analysis for image tampering detection. In International Workshop on Digital Watermarking (pp. 136–146). Springer.

Bandelt, H.-J. & Dress, A. W. M. (1992). A canonical decomposition theory for metrics on a finite set. Advances in Mathematics, 92(1), 47–105.

Bandt, C. & Pompe, B. (2002). Permutation entropy: A natural complexity measure for time series. Physical Review Letters, 88(17), 174102.

Barabási, A.-L. (2016). Network Science. Cambridge University Press.

Battistello, G., Moreno-Rodriguez, S., Volle, E. & Lopez-Persem, A. (2025). Subjective valuation as a domain-general process in creative thinking. Communications Psychology.

Bell, P. & Ommer, B. (2019). Computer vision and the analysis of art and cultural heritage. International Journal of Digital Art History, 4, 1–18.

Bender, E. M., Gebru, T., McMillan-Major, A. & Shmitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big? In Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (pp. 610–623).

Berlyne, D. E. (1971). Aesthetics and Psychobiology. Appleton-Century-Crofts.

Berns, R. S. (2019). Billmeyer and Saltzman's Principles of Color Technology (4e éd.). Wiley.

Birhane, A. (2022). The unseen Black faces of AI algorithms. Nature, 610, 451–452.

Birkhoff, G. D. (1933). Aesthetic Measure. Harvard University Press.

Blinkov, S. M. & Glezer, I. I. (1968). The Human Brain in Figures and Tables: A Quantitative Handbook (trad. B. Haigh de l'édition russe, Leningrad, 1964). Basic Books / Plenum Press.

Blondel, V. D., Guillaume, J.-L., Lambiotte, R. & Lefebvre, E. (2008). Fast unfolding of communities in large networks. Journal of Statistical Mechanics: Theory and Experiment, 2008(10), P10008.

Bo, Y., Yu, J. & Zhang, K. (2018). Computational aesthetics and applications. Visual Computing for Industry, Biomedicine, and Art, 1, 6.

Borji, A. & Itti, L. (2013). State-of-the-art in visual attention modeling. IEEE Transactions on Pattern Analysis and Machine Intelligence, 35(1), 185–207.

Bouckaert, R., Lemey, P., Dunn, M., Greenhill, S. J., Alekseyenko, A. V., Drummond, A. J., Gray, R. D., Suchard, M. A. & Atkinson, Q. D. (2012). Mapping the origins and expansion of the Indo-European language family. Science, 337(6097), 957–960.

Bracewell, R. N. (1986). The Fourier Transform and Its Applications (2e éd.). McGraw-Hill.

Brachmann, A. & Redies, C. (2017). Computational and experimental approaches to visual aesthetics. Frontiers in Computational Neuroscience, 11, 102.

Brielmann, A. A. & Pelli, D. G. (2018). Aesthetics. Current Biology, 28(16), R859–R863.

Bruna, J. & Mallat, S. (2013). Invariant scattering convolution networks. IEEE Transactions on Pattern Analysis and Machine Intelligence, 35(8), 1872–1886.

Bubenik, P. (2015). Statistical topological data analysis using persistence landscapes. Journal of Machine Learning Research, 16, 77–102.

Buck, J. N. (1948). The H-T-P technique: A qualitative and quantitative scoring manual. Journal of Clinical Psychology, 4(4), 317–396.

Campbell, F. W. & Robson, J. G. (1968). Application of Fourier analysis to the visibility of gratings. The Journal of Physiology, 197(3), 551–566.

Campello, R. J. G. B., Moulavi, D. & Sander, J. (2013). Density-based clustering based on hierarchical density estimates. In Pacific-Asia Conference on Knowledge Discovery and Data Mining (pp. 160–172). Springer.

Canny, J. (1986). A computational approach to edge detection. IEEE Transactions on Pattern Analysis and Machine Intelligence, PAMI-8(6), 679–698.

Cardinal, R. (1972). Outsider Art. Praeger.

Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A. & Zagoruyko, S. (2020). End-to-end object detection with transformers. In European Conference on Computer Vision (pp. 213–229). Springer.

Carlsson, G. (2009). Topology and data. Bulletin of the American Mathematical Society, 46(2), 255–308.

Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P. & Joulin, A. (2021). Emerging properties in self-supervised vision transformers. In Proceedings of the IEEE/CVF International Conference on Computer Vision (pp. 9650–9660).

Cetinic, E., Lipic, T. & Grgic, S. (2018). Fine-tuning convolutional neural networks for fine art classification. Expert Systems with Applications, 114, 107–118.

Chatterjee, A. (2003). Prospects for a cognitive neuroscience of visual aesthetics. Bulletin of Psychology and the Arts, 4(2), 55–60.

Chatterjee, A. (2014). The Aesthetic Brain: How We Evolved to Desire Beauty and Enjoy Art. Oxford University Press.

CIE (Commission Internationale de l’Éclairage) (1976). Colorimetry. Official Recommendations of the International Commission on Illumination. Publication CIE n° 15. Vienne.

Crutchfield, J. P. (2012). Between order and chaos. Nature Physics, 8(1), 17–24.

Dalal, N. & Triggs, B. (2005). Histograms of oriented gradients for human detection. In 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (vol. 1, pp. 886–893).

Das, M., Chowdary, S., Das, S., Goyal, N. et al. (2024). Deep learning models for classification of human figure drawings into psychiatric diagnostic labels: A proof-of-concept study. SSRN preprint.

Datta, R., Joshi, D., Li, J. & Wang, J. Z. (2006). Studying aesthetics in photographic images using a computational approach. In European Conference on Computer Vision (pp. 288–301). Springer.

Daubechies, I. (1988). Orthonormal bases of compactly supported wavelets. Communications on Pure and Applied Mathematics, 41(7), 909–996.

Daubechies, I. (1992). Ten Lectures on Wavelets. SIAM.

Daugman, J. G. (1985). Uncertainty relation for resolution in space, spatial frequency, and orientation optimized by two-dimensional visual cortical filters. Journal of the Optical Society of America A, 2(7), 1160–1169.

De Valois, R. L. & De Valois, K. K. (1990). Spatial Vision. Oxford University Press.

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K. & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. In IEEE Conference on Computer Vision and Pattern Recognition (pp. 248–255).

Di Cicco, F., Wijntjes, M. W. A. & Pont, S. C. (2020). If painters give you lemons, squeeze the knowledge out of them: A study on the visual perception of the translucent and juicy appearance of citrus fruits in paintings. Journal of Vision, 20(13), 12.

Don, A. P. H., Jurova, A. & Skorobogatova, M. (2024). Art's hidden topology: A window into human perception. bioRxiv, 2024.10.16.618741.

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T. et al. (2021). An image is worth 16 × 16 words: Transformers for image recognition at scale. In International Conference on Learning Representations.

Dubois, A.-M. (2020). Les psychothérapies à médiation artistique. Annales Médico-Psychologiques, 178(1), 48–51.

Dubois, A.-M. (dir.) (2017). Entre art des fous et art brut. La Collection Sainte-Anne. Paris : Somogy Éditions d'Art – MAHHSA.

Dubois, A.-M. (dir.) (2018). De l'art des fous à l'art psychopathologique. La Collection Sainte-Anne. Paris : Somogy Éditions d'Art – MAHHSA.

Dubois, A.-M. (dir.) (2024). Écrire l'image. Paris : MAHHSA.

Dubuffet, J. (1949). L'art brut préféré aux arts culturels. Galerie René Drouin, Paris.

Edelsbrunner, H. & Harer, J. (2010). Computational Topology: An Introduction. American Mathematical Society.

Efron, B. (1979). Bootstrap methods: Another look at the jackknife. The Annals of Statistics, 7(1), 1–26.

Elgammal, A., Kang, Y. & den Leeuw, M. (2018). Picasso, Matisse, or a fake? Automated analysis of drawings at the stroke level for attribution and authentication. In Proceedings of the AAAI Conference on Artificial Intelligence, 32(1).

Elgammal, A., Mazzone, M., Liu, B., Kim, D. & Elhoseiny, M. (2018). The shape of art history in the eyes of the machine. In Proceedings of the AAAI Conference on Artificial Intelligence, 32(1).

Fairbanks, M. S., Mureika, J. R. & Taylor, R. P. (2010). Multifractal and statistical comparison of painting techniques of adults and children. SPIE Proceedings of Electronic Imaging, 7531, 1–6.

Fairchild, M. D. (2013). Color Appearance Models (3e éd.). Wiley.

Falconer, K. (2003). Fractal Geometry: Mathematical Foundations and Applications (2e éd.). Wiley.

Felsenstein, J. (1985). Confidence limits on phylogenies: An approach using the bootstrap. Evolution, 39(4), 783–791.

Field, D. J. (1987). Relations between the statistics of natural images and the response properties of cortical cells. Journal of the Optical Society of America A, 4(12), 2379–2394.

Flash, T. & Hogan, N. (1985). The coordination of arm movements: An experimentally confirmed mathematical model. The Journal of Neuroscience, 5(7), 1688–1703.

Forsythe, A., Williams, T. & Reilly, R. G. (2017). What paint can tell us: A fractal analysis of neurological changes in seven artists. Neuropsychology, 31(1), 1–10.

Gaillard, R. (2022). Un coup de hache dans la tête : folie et créativité. Grasset.

Garcia, N., Renoust, B. & Nakashima, Y. (2020). ContextNet: Representation and exploration for painting classification and retrieval in context. International Journal of Multimedia Information Retrieval, 9(1), 17–30.

Gatys, L. A., Ecker, A. S. & Bethge, M. (2016). Image style transfer using convolutional neural networks. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 2414–2423).

Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M. & Wichmann, F. A. (2020). Shortcut learning in deep neural networks. Nature Machine Intelligence, 2(11), 665–673.

Goodenough, F. L. (1926). Measurement of Intelligence by Drawings. World Book Company.

Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A. & Bengio, Y. (2014). Generative adversarial networks. Advances in Neural Information Processing Systems, 27.

Goodfellow, I. J., Shlens, J. & Szegedy, C. (2015). Explaining and harnessing adversarial examples. In International Conference on Learning Representations.

Goupillaud, P., Grossmann, A. & Morlet, J. (1984). Cycle-octave and related transforms in seismic signal analysis. Geoexploration, 23(1), 85–102.

Graham, D. J. & Field, D. J. (2007). Statistical regularities of art images and natural scenes: Spectra, sparseness and nonlinearities. Spatial Vision, 21(1), 149–164.

Graham, D. J. & Meng, M. (2011). Altered spatial frequency content in paintings by artists with schizophrenia. i-Perception, 2(1), 1–9.

Haar, A. (1910). Zur Theorie der orthogonalen Funktionensysteme. Mathematische Annalen, 69(3), 331–371.

Hacking, S., Foreman, D. & Belcher, J. (1996). The descriptive assessment for psychiatric art: A new way of quantifying paintings by psychiatric patients. The Journal of Nervous and Mental Disease, 184, 425–430.

Hacking, S. & Foreman, D. (2000). The descriptive assessment for psychiatric art (DAPA): Update and further research. The Journal of Nervous and Mental Disease, 188(8), 525–529.

Haralick, R. M., Shanmugam, K. & Dinstein, I. (1973). Textural features for image classification. IEEE Transactions on Systems, Man, and Cybernetics, SMC-3(6), 610–621.

Hayn-Leichsenring, G. U., Lehmann, T. & Redies, C. (2017). Subjective ratings of beauty and aesthetics: Correlations with statistical image properties in Western oil paintings. i-Perception, 8(3), 1–21.

He, K., Zhang, X., Ren, S. & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 770–778).

Health Data Hub. Le data challenge Outs[AI]der. https://www.health-data-hub.fr/page/le-data-challenge-outsaider

Henemann, G. M., Brachmann, A. & Redies, C. (2017). Statistical image properties in works from the Prinzhorn Collection of artists with schizophrenia. Frontiers in Psychiatry, 8, 273.

Hennig, W. (1966). Phylogenetic Systematics. University of Illinois Press.

Howe, C. J., Barbrook, A. C., Spencer, M., Robinson, P., Bordalejo, B. & Mooney, L. R. (2001). Manuscript evolution. Trends in Genetics, 17(3), 147–152.

Hughes, J. M., Graham, D. J. & Rockmore, D. N. (2010). Quantification of artistic style through sparse coding analysis in the drawings of Pieter Bruegel the Elder. Proceedings of the National Academy of Sciences, 107(4), 1279–1283.

Itti, L., Koch, C. & Niebur, E. (1998). A model of saliency-based visual attention for rapid scene analysis. IEEE Transactions on Pattern Analysis and Machine Intelligence, 20(11), 1254–1259.

Itti, L. & Koch, C. (2001). Computational modelling of visual attention. Nature Reviews Neuroscience, 2(3), 194–203.

Johnson, C. R., Hendriks, E., Berezhnoy, I. J., Brevdo, E., Hughes, S. M., Daubechies, I., Li, J., Postma, E. & Wang, J. Z. (2008). Image processing for artist identification: Computerized analysis of Vincent van Gogh's painting brushstrokes. IEEE Signal Processing Magazine, 25(4), 37–48.

Jones-Smith, K. & Mathur, H. (2006). Fractal analysis: Revisiting Pollock's drip paintings. Nature, 444(7119), E9–E10.

Kim, D., Son, S.-W. & Jeong, H. (2014). Large-scale quantitative analysis of painting arts. Scientific Reports, 4, 7370.

Kipf, T. N. & Welling, M. (2017). Semi-supervised classification with graph convolutional networks. In International Conference on Learning Representations.

Kittler, F. A. (1985). Aufschreibesysteme 1800/1900. Wilhelm Fink (trad. angl. Discourse Networks 1800/1900, Stanford University Press, 1990).

Kittler, F. A. (1986). Grammophon, Film, Typewriter. Brinkmann & Bose (trad. fr. Gramophone, Film, Typewriter, Les Presses du réel, 2018).

Koch, C. & Ullman, S. (1985). Shifts in selective visual attention: Towards the underlying neural circuitry. Human Neurobiology, 4(4), 219–227.

Koch, M., Denzler, J. & Redies, C. (2010). $1/f^2$ characteristics and isotropy in the Fourier power spectra of visual art, cartoons, comics, mangas, and different categories of photographs. PLOS ONE, 5(8), e12268.

Koffka, K. (1935). Principles of Gestalt Psychology. Harcourt, Brace & World.

Kolmogorov, A. N. (1965). Three approaches to the quantitative definition of information. Problems of Information Transmission, 1(1), 1–7.

Krizhevsky, A., Sutskever, I. & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. Advances in Neural Information Processing Systems, 25, 1097–1105.

Kümmerer, M., Wallis, T. S. A. & Bethge, M. (2017). DeepGaze II: Reading fixations from deep features trained on object recognition. arXiv preprint, arXiv:1610.01563.

Lang, S. & Ommer, B. (2021). Transforming information into knowledge: How computational methods reshape art history. Digital Humanities Quarterly, 15(3).

Lapuschkin, S., Wäldchen, S., Binder, A., Montavon, G., Samek, W. & Müller, K.-R. (2019). Unmasking Clever Hans predictors and assessing what machines really learn. Nature Communications, 10, 1096.

Le Bomin, S., Lecointre, G. & Heyer, E. (2016). The evolution of musical diversity: The key role of vertical transmission. PLOS ONE, 11(3), e0151570.

LeCun, Y., Bottou, L., Bengio, Y. & Haffner, P. (1998). Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11), 2278–2324.

LeCun, Y., Bengio, Y. & Hinton, G. (2015). Deep learning. Nature, 521, 436–444.

Lee, B., Seo, M. K., Kim, D., Shin, I.-S., Schich, M., Jeong, H. & Han, S. K. (2020). Dissecting landscape art history with information theory. Proceedings of the National Academy of Sciences, 117(43), 26580–26590.

Lefebvre, T. (2018). La Collection Sainte-Anne (à propos de Dubois A.-M., Entre art des fous et art brut). Revue d'histoire de la pharmacie, 105(398), 264.

Li, M. & Vitányi, P. (2008). An Introduction to Kolmogorov Complexity and Its Applications (3e éd.). Springer.

Li, J., Li, D., Xiong, C. & Hoi, S. (2022). BLIP: Bootstrapping language-image pre-training for unified vision-language understanding and generation. In International Conference on Machine Learning (pp. 12888–12900).

Liang, S. et al. (2025). Enhancing artistic style classification through a novel ArtFusionNet framework. Scientific Reports.

Liu, L., Wang, Y., Sinatra, R., Giles, C. L., Song, C. & Wang, D. (2018). Hot streaks in artistic, cultural, and scientific careers. Nature, 559, 396–399.

Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S. & Guo, B. (2021). Swin Transformer: Hierarchical vision transformer using shifted windows. In Proceedings of the IEEE/CVF International Conference on Computer Vision (pp. 10012–10022).

Liu, Z., Mao, H., Wu, C.-Y., Feichtenhofer, C., Darrell, T. & Xie, S. (2022). A ConvNet for the 2020s. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (pp. 11976–11986).

Liu, Y., Bai, H. & Wang, J. (2024a). Fine-art recognition using convolutional transformers. PeerJ Computer Science, 10, e2409.

Liu, H., Li, C., Wu, Q. & Lee, Y. J. (2024b). Visual instruction tuning. Advances in Neural Information Processing Systems, 36.

Lundberg, S. M. & Lee, S.-I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems, 30, 4765–4774.

Lyu, S., Rockmore, D. & Farid, H. (2004). A digital technique for art authentication. Proceedings of the National Academy of Sciences, 101(49), 17006–17010.

Ma, F. & Li, H. (2023). Online painting image clustering for the mental health of college art students based on improved CNN and SMOTE. PeerJ Computer Science, 9, e1462.

Mace, R., Holden, C. J. & Shennan, S. (Eds.). (2005). The Evolution of Cultural Diversity: A Phylogenetic Approach. UCL Press.

MacGregor, J. M. (1989). The Discovery of the Art of the Insane. Princeton University Press.

Machover, K. (1949). Personality Projection in the Drawing of the Human Figure. Charles C. Thomas.

MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. In Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability (vol. 1, pp. 281–297).

Mallat, S. G. (1989). A theory for multiresolution signal decomposition: The wavelet representation. IEEE Transactions on Pattern Analysis and Machine Intelligence, 11(7), 674–693.

Mallat, S. (2008). A Wavelet Tour of Signal Processing (3e éd.). Academic Press.

Mallat, S. (2012). Group invariant scattering. Communications on Pure and Applied Mathematics, 65(10), 1331–1398.

Mandelbrot, B. B. (1983). The Fractal Geometry of Nature. W. H. Freeman.

Marek, S., Tervo-Clemmens, B., Calabro, F. J. et al. (2022). Reproducible brain-wide association studies require thousands of individuals. Nature, 603(7902), 654–660.

Massaro, D., Savazzi, F., Di Dio, C., Freedberg, D., Gallese, V., Gilli, G. & Marchetti, A. (2012). When art moves the eyes: A behavioral and eye-tracking study. PLOS ONE, 7(5), e37285.

McInnes, L., Healy, J. & Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for dimension reduction. arXiv preprint, arXiv:1802.03426.

McManus, I. C., Stöver, K. & Kim, D. (2011). Arnheim’s gestalt theory of visual balance: Examining the compositional structure of art. i-Perception, 2(6), 615–647.

Mendenhall, T. C. (1887). The characteristic curves of composition. Science, 9(214S), 237–246.

Meyer, Y. (1990). Ondelettes et opérateurs (Vol. I : Ondelettes). Hermann.

Morgenthaler, W. (1921). Ein Geisteskranker als Künstler (Adolf Wölfli). Ernst Bircher.

Munnangi, R. R. & Giunti, B. (2025). The persistence of painting styles. arXiv preprint, arXiv:2511.16695.

Mureika, J. R., Cupchik, G. C. & Dyer, C. C. (2005). Multifractal structure in nonrepresentational art. Physical Review E, 72(4), 046101.

Mureika, J. R. & Taylor, R. P. (2013). The abstract expressionists and Les Automatistes: A shared multi-fractal depth? Signal Processing, 93(3), 573–578.

Nakauchi, S. & Tamura, H. (2022). Regularity of colour statistics in explaining colour composition preferences in art paintings. Scientific Reports, 12, 14585.

Newman, M. E. J. (2010). Networks: An Introduction. Oxford University Press.

Ojala, T., Pietikäinen, M. & Mäenpää, T. (2002). Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. IEEE Transactions on Pattern Analysis and Machine Intelligence, 24(7), 971–987.

Olshausen, B. A. & Field, D. J. (1996). Emergence of simple-cell receptive field properties by learning a sparse code for natural images. Nature, 381, 607–609.

Oquab, M., Darcet, T., Moutakanni, T., Vo, H. et al. (2024). DINOv2: Learning robust visual features without supervision. Transactions on Machine Learning Research.

Organisciak, P. & Dumas, D. Open Creativity Scoring with Artificial Intelligence (OCSAI). University of Denver. https://openscoring.du.edu/

Osu, R., Ota, K., Fujiwara, T., Otaka, Y., Kawato, M. & Liu, M. (2011). Quantifying the quality of hand movement in stroke patients through three-dimensional curvature. Journal of NeuroEngineering and Rehabilitation, 8, 62.

Otter, N., Porter, M. A., Tillmann, U., Grindrod, P. & Harrington, H. A. (2017). A roadmap for the computation of persistent homology. EPJ Data Science, 6, 17.

Panofsky, E. (1939). Studies in Iconology: Humanistic Themes in the Art of the Renaissance. Oxford University Press.

Patterson, J. D., Barbot, B., Lloyd-Cox, J. & Beaty, R. E. (2024). AuDrA: An automated drawing assessment platform for evaluating creativity. Behavior Research Methods, 56, 3619–3636.

Peiry, L. (2001). Art Brut: The Origins of Outsider Art. Flammarion.

Perc, M. (2020). Beauty in artistic expression through the eyes of networks and physics. Journal of the Royal Society Interface, 17, 20190686.

Piechowski-Jóźwiak, B. & Bogousslavsky, J. (2018). Dementia and change of style: Willem de Kooning. Frontiers of Neurology and Neuroscience, 43, 96–104.

Polatkan, G., Jafarpour, S., Brasoveanu, A., Hughes, S. & Daubechies, I. (2009). Detection of forgery in paintings using supervised learning. In IEEE International Conference on Image Processing (pp. 2921–2924).

Prinzhorn, H. (1922). Bildnerei der Geisteskranken: Ein Beitrag zur Psychologie und Psychopathologie der Gestaltung. Springer.

Quaak, M., van de Mortel, L., Thomas, R. M. & van Wingen, G. (2021). Deep learning applications for the classification of psychiatric disorders using neuroimaging data: Systematic review and meta-analysis. NeuroImage: Clinical, 30, 102584.

Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S. et al. (2021). Learning transferable visual models from natural language supervision. In International Conference on Machine Learning (pp. 8748–8763).

Redies, C., Hasenstein, J. & Denzler, J. (2007). Fractal-like image statistics in visual art: Similarity to natural scenes. Spatial Vision, 21(1), 137–148.

Redies, C. (2007). A universal model of esthetic perception based on the sensory coding of natural stimuli. Spatial Vision, 21(1), 97–117.

Redmon, J., Divvala, S., Girshick, R. & Farhadi, A. (2016). You only look once: Unified, real-time object detection. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 779–788).

Rhodes, C. (2000). Outsider Art: Spontaneous Alternatives. Thames & Hudson.

Roberto, J., Ortego, D. & Davis, B. (2020). Toward the automatic retrieval and annotation of outsider art images: A preliminary statement. In Proceedings of the 1st International Workshop on Artificial Intelligence for Historical Image Enrichment and Access (AI4HI 2020), LREC 2020 (pp. 16–22). European Language Resources Association.

Roberto, J. & Davis, B. (2020). Towards the ontologization of the outsider art domain: Position paper. In Proceedings of the 16th Joint ACL-ISO Workshop on Interoperable Semantic Annotation (ISA-16), LREC 2020 (pp. 94–101). European Language Resources Association.

Robinson, P. & O'Hara, R. J. (1996). Cladistic analysis of an Old Norse manuscript tradition. In Research in Humanities Computing 4 (pp. 115–137). Oxford University Press.

Rombach, R., Blattmann, A., Lorenz, D., Esser, P. & Ommer, B. (2022). High-resolution image synthesis with latent diffusion models. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (pp. 10684–

10695).

Romero, J., Gómez-Robledo, L. & Nieves, J. L. (2018). Computational color analysis of paintings for different artists of the XVI and XVII centuries. Color Research & Application, 43(6), 943–953.

Rosso, O. A., Larrondo, H. A., Martin, M. T., Plastino, A. & Fuentes, M. A. (2007). Distinguishing noise from chaos. Physical Review Letters, 99(15), 154102.

Rubin, E. (1915). Synsoplevede Figurer. Gyldendalske Boghandel, Copenhague.

Ruderman, D. L. (1994). The statistics of natural images. Network: Computation in Neural Systems, 5(4), 517–548.

Ruiz de Miras, J., Vílchez, J. L., Gacto, M. J. & Martín, D. (2026). Painting authentication using CNNs and sliding window feature extraction. Frontiers in Artificial Intelligence, 8, 1738444.

Saitou, N. & Nei, M. (1987). The neighbor-joining method: A new method for reconstructing phylogenetic trees. Molecular Biology and Evolution, 4(4), 406–425.

Schich, M., Song, C., Ahn, Y.-Y., Mirsky, A., Martino, M., Barabási, A.-L. & Helbing, D. (2014). A network framework of cultural history. Science, 345(6196), 558–562.

Selim, A., Elgharib, M. & Doyle, L. (2016). Painting style transfer for head portraits using convolutional neural networks. ACM Transactions on Graphics, 35(4), 1–18.

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D. & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. In Proceedings of the IEEE International Conference on Computer Vision (pp. 618–626).

Shannon, C. E. (1948). A mathematical theory of communication. Bell System Technical Journal, 27(3), 379–423.

Shapley, L. S. (1953). A value for n-person games. In H. W. Kuhn & A. W. Tucker (Eds.), Contributions to the Theory of Games (Vol. II, pp. 307–317). Princeton University Press.

Sharma, G., Wu, W. & Dalal, E. N. (2005). The CIEDE2000 color-difference formula: Implementation notes, supplementary test data, and mathematical observations. Color Research & Application, 30(1), 21–30.

Shen, H., Wang, S.-H., Zhang, Y., Wang, H., Li, F., Lucas, M. V., Zhang, Y.-D., Liu, Y. & Yuan, T.-F. (2021). Color painting predicts clinical symptoms in chronic schizophrenia patients via deep learning. BMC Psychiatry, 21, 522.

Sifre, L. & Mallat, S. (2013). Rotation, scaling and deformation invariant scattering for texture discrimination. In IEEE Conference on Computer Vision and Pattern Recognition (pp. 1233–1240).

Sigaki, H. Y. D., Perc, M. & Ribeiro, H. V. (2018). History of art paintings through the lens of entropy and complexity. Proceedings of the National Academy of Sciences, 115(37), E8585–E8594.

Simondon, G. (1958). Du mode d'existence des objets techniques. Aubier.

Simonyan, K. & Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. In International Conference on Learning Representations.

Smith, A. R. (1978). Color gamut transform pairs. ACM SIGGRAPH Computer Graphics, 12(3), 12–19.

Smith, J. H., Holt, C., Smith, N. H. & Taylor, R. P. (2024). Using machine learning to distinguish between authentic and imitation Jackson Pollock poured paintings: A tile-driven approach to computer vision. PLOS ONE, 19(6), e0302962.

Sobel, I. & Feldman, G. (1968). A 3 × 3 isotropic gradient operator for image processing. Présenté au Stanford Artificial Intelligence Project (SAIL).

Spee, B. T. M., Sladky, R., Fingerhut, J., Laciny, A., Kraus, C., Carls-Diamante, S. et al. (2023). Machine learning revealed symbolism, emotionality, and imaginativeness as primary predictors of creativity evaluations of Western art paintings. Scientific Reports, 13, 22232.

Spehar, B., Clifford, C. W. G., Newell, B. R. & Taylor, R. P. (2003). Universal aesthetic of fractals. Computers & Graphics, 27(5), 813–820.

Stanley, H. E. & Meakin, P. (1988). Multifractal phenomena in physics and chemistry. Nature, 335, 405–409.

Stork, D. G. (2009). Computer vision and computer graphics analysis of paintings and drawings: An introduction to the literature. In International Conference on Computer Analysis of Images and Patterns (pp. 9–24). Springer.

Sánchez, J. A., Romero, V., Toselli, A. H., Villegas, M. & Vidal, E. (2019). A set of benchmarks for handwritten text recognition on historical documents. Pattern Recognition, 94, 122–134.

Tan, M. & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. In International Conference on Machine Learning (pp. 6105–6114).

Taylor, R. P., Micolich, A. P. & Jonas, D. (1999). Fractal analysis of Pollock's drip paintings. Nature, 399, 422.

Tehrani, J. & Collard, M. (2002). Investigating cultural evolution through biological phylogenetic analyses of Turkmen textiles. Journal of Anthropological Archaeology, 21(4), 443–463.

Thévoz, M. (1975). L'Art brut. Skira.

Thévoz, M. (1979). Écrits bruts. Presses Universitaires de France.

Tolhurst, D. J., Tadmor, Y. & Chao, T. (1992). Amplitude spectra of natural images. Ophthalmic and Physiological Optics, 12(2), 229–232.

Tuceryan, M. & Jain, A. K. (1993). Texture analysis. In Handbook of Pattern Recognition and Computer Vision (pp. 235–276). World Scientific.

van Dantzig, M. M. (1973). Pictology: An Analytical Method for Attribution and Evaluation of Pictures. E. J. Brill.

van der Maaten, L. & Hinton, G. (2008). Visualizing data using t-SNE. Journal of Machine Learning Research, 9, 2579–2605.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł. & Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30.

Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P. & Bengio, Y. (2018). Graph attention networks. In International Conference on Learning Representations.

Vessel, E. A., Starr, G. G. & Rubin, N. (2012). The brain on art: Intense aesthetic experience activates the default mode network. Frontiers in Human Neuroscience, 6, 66.

Vieira, V., Fabbri, R., Sbrissa, D., da Fontoura Costa, L. & Travieso, G. (2015). A quantitative approach to painting styles. Physica A, 417, 110–129.

Vinyals, O., Toshev, A., Bengio, S. & Erhan, D. (2015). Show and tell: A neural image caption generator. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 3156–3164).

Volmat, R. (1956). L'art psychopathologique. Presses Universitaires de France.

Wagemans, J., Elder, J. H., Kubovy, M., Palmer, S. E., Peterson, M. A., Singh, M. & von der Heydt, R. (2012a). A century of Gestalt psychology in visual perception: I. Perceptual grouping and figure-ground organization. Psychological Bulletin, 138(6), 1172–1217.

Wagemans, J., Feldman, J., Gepshtein, S., Kimchi, R., Pomerantz, J. R., van der Helm, P. A. & van Leeuwen, C. (2012b). A century of Gestalt psychology in visual perception: II. Conceptual and theoretical foundations. Psychological Bulletin, 138(6), 1218–1252.

Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. Journal of the American Statistical Association, 58(301), 236–244.

Wertheimer, M. (1923). Untersuchungen zur Lehre von der Gestalt II. Psychologische Forschung, 4, 301–350.

Wiatowski, T. & Bölcskei, H. (2018). A mathematical theory of deep convolutional neural networks for feature extraction. IEEE Transactions on Information Theory, 64(3), 1845–1866.

Windram, H. F., Shaw, P., Robinson, P. & Howe, C. J. (2008). Dante's Monarchia as a test case for the use of phylogenetic methods in stemmatic analysis. Literary and Linguistic Computing, 23(4), 443–463.

Woerther, F. & Khonsari, R. H. (2001). L'application des programmes de reconstruction phylogénétique sur ordinateur à l'étude de la tradition manuscrite d'un texte : l'exemple du chapitre XI de l'Ars Rhetorica du Pseudo-Denys d'Halicarnasse. Revue d'histoire des textes, 31, 227–240.

Wyszecki, G. & Stiles, W. S. (1982). Color Science: Concepts and Methods, Quantitative Data and Formulae (2e éd.). Wiley.

Yamins, D. L. K. & DiCarlo, J. J. (2016). Using goal-driven deep learning models to understand sensory cortex. Nature Neuroscience, 19(3), 356–365.

Yu, L. (2026). Visual perception based deep learning transformers for classifying paintings and photographs through feature extraction. Scientific Reports, 16, 5326.

Zhao, W., Zhou, D., Qiu, X. & Jiang, W. (2021). Compare the performance of the models in art classification. PLOS ONE, 16(3), e0248414.

Zhao, Y., Stumpel, J., de Ridder, H. & Wijntjes, M. W. A. (2023). Zooming in on style: Exploring style perception using details of paintings. Journal of Vision, 23(6), 2.

1. Le titre reprend celui de Blinkov, S. M. & Glezer, I. I. (1968). The Human Brain in Figures and Tables: A Quantitative Handbook (trad. B. Haigh de l'édition russe, Leningrad, 1964). Basic Books / Plenum Press — 482 p. et 305 tableaux, entreprise soviétique de quantification du cerveau humain qui fait ici office de précédent et d'avertissement.

2. Health Data Hub. Le data challenge Outs[AI]der. https://www.health-data-hub.fr/page/le-data-challenge-outsaider

3. Taylor, R. P., Micolich, A. P. & Jonas, D. (1999). Fractal analysis of Pollock's drip paintings. Nature, 399, 422. Sur les ciels de Van Gogh : Aragón, J. L., Naumis, G. G., Bai, M., Torres, M. & Maini, P. K. (2008). Turbulent luminance in impassioned van Gogh paintings. Journal of Mathematical Imaging and Vision, 30, 275-283.

4. Pour Bruegel : Hughes, J. M., Graham, D. J. & Rockmore, D. N. (2010). Quantification of artistic style through sparse coding analysis in the drawings of Pieter Bruegel the Elder. Proceedings of the National Academy of Sciences, 107(4), 1279-1283. Pour Van Gogh : Johnson, C. R., Hendriks, E., Berezhnoy, I. J., Brevdo, E., Hughes, S. M., Daubechies, I., Li, J., Postma, E. & Wang, J. Z. (2008). Image processing for artist identification: Computerized analysis of Vincent van Gogh's painting brushstrokes. IEEE Signal

Processing Magazine, 25(4), 37-48. Pour Picasso, Matisse et Schiele : Elgammal, A., Kang, Y. & den Leeuw, M. (2018). Picasso, Matisse, or a fake? Automated analysis of drawings at the stroke level for attribution and authentication. In Proceedings of the AAAI Conference on Artificial Intelligence, 32(1). Voir § 11 (partie II).

5. Gaillard, R. (2022). Un coup de hache dans la tête : folie et créativité. Grasset. Le lien entre trouble psychiatrique et création n'est pas une surreprésentation du trouble chez les artistes, mais un lien familial et génétique. Il n'y a pas d'argument épidémiologique à ce jour pour remettre en cause la pertinence d'un groupe contrôle issu de collections d'art contemporain.

6. Roberto, J., Ortego, D. & Davis, B. (2020). Toward the automatic retrieval and annotation of outsider art images: A preliminary statement. In Proceedings of the 1st International Workshop on Artificial Intelligence for Historical Image Enrichment and Access (AI4HI 2020), LREC 2020 (pp. 16-22). European Language Resources Association. Voir § 12.5.2 (partie II).

7. Yamins, D. L. K. & DiCarlo, J. J. (2016). Using goal-driven deep learning models to understand sensory cortex. Nature Neuroscience, 19(3), 356-365. Sur le codage en fréquences spatiales du cortex visuel primaire : Campbell, F. W. & Robson, J. G. (1968). Application of Fourier analysis to the visibility of gratings. The Journal of Physiology, 197(3), 551-566. Voir § 4.1 et 4.2 (partie II).

8. Graham, D. J. & Meng, M. (2011). Altered spatial frequency content in paintings by artists with schizophrenia. i-Perception, 2(1), 1-9. Voir § 1.3 (partie II).

9. Sigaki, H. Y. D., Perc, M. & Ribeiro, H. V. (2018). History of art paintings through the lens of entropy and complexity. Proceedings of the National Academy of Sciences, 115(37), E8585-E8594. Les deux descripteurs sont l'entropie de permutation et la complexité statistique ; Voir § 8.2 et 8.3 (partie II).

10. Voir supra, note 13.

11. Spee, B. T. M., Sladky, R., Fingerhut, J., Laciny, A., Kraus, C., Carls-Diamante, S. et al. (2023). Machine learning revealed symbolism, emotionality, and imaginativeness as primary predictors of creativity evaluations of Western art paintings. Scientific Reports, 13, 22232.

12. Patterson, J. D., Barbot, B., Lloyd-Cox, J. & Beaty, R. E. (2024). AuDrA: An automated drawing assessment platform for evaluating creativity. Behavior Research Methods, 56, 3619-3636 ; Organisciak, P. & Dumas, D. Open Creativity Scoring with Artificial Intelligence (OCSAI). University of Denver. https://openscoring.du.edu/ ; CAP: The creativity assessment platform for online testing and automated scoring (2025). Behavior Research Methods. https://doi.org/10.3758/s13428-025-02761-9

13. Battistello, G., Moreno-Rodriguez, S., Volle, E. & Lopez-Persem, A. (2025). Subjective valuation as a domain-general process in creative thinking. Communications Psychology. Ces travaux, conduits à l'Institut du Cerveau (Paris), décrivent la sélection d'idées au cours de la pensée créative comme un processus de valuation subjective comparable à celui de la décision économique.

14. Henemann, G. M., Brachmann, A. & Redies, C. (2017). Statistical image properties in works from the Prinzhorn Collection of artists with schizophrenia. Frontiers in Psychiatry, 8, 273. Voir § 1.2 (partie II).

15. Piechowski-Jóźwiak, B. & Bogousslavsky, J. (2018). Dementia and change of style: Willem de Kooning. Frontiers of Neurology and Neuroscience, 43, 96-104 ; Forsythe, A., Williams, T. & Reilly, R. G. (2017). What paint can tell us: A fractal analysis of neurological changes in seven artists. Neuropsychology, 31(1), 1-10. Voir § 15.3 (partie II).

16. Jones-Smith, K. & Mathur, H. (2006). Fractal analysis: Revisiting Pollock's drip paintings. Nature, 444(7119), E9-E10. Voir § 5.3.4 (partie II).

17. Marek, S., Tervo-Clemmens, B., Calabro, F. J. et al. (2022). Reproducible brain-wide association studies require thousands of individuals. Nature, 603(7902), 654-660. Les auteurs montrent que la reproductibilité des associations cerveau-phénotype reste faible en deçà de mille sujets, alors que la taille médiane d'une étude de neuro-imagerie est d'environ vingt-cinq.

18. CIDOC-CRM (norme ISO 21127) est le modèle conceptuel de référence du Conseil international des musées pour décrire le patrimoine culturel ; il définit un vocabulaire commun d'événements (création, exposition, restauration) et d'entités (œuvre, personne, lieu, matériau). L'Europeana Data Model (EDM) est le format d'agrégation utilisé par la bibliothèque numérique européenne Europeana. Les Getty Vocabularies sont des vocabulaires contrôlés multilingues maintenus par le Getty Research Institute ; le plus connu, l'Union List of Artist Names (ULAN), répertorie de manière unifiée les noms et variantes d'attribution des artistes.

19. Les principales familles d’ondelettes utilisées en analyse d’image sont l’ondelette de Haar (Haar, 1910), la plus simple, à valeurs discrètes ; les ondelettes de Daubechies (Daubechies, 1988, 1992), à support compact et orthogonales ; les ondelettes de Morlet (Goupillaud, Grossmann et Morlet, 1984), complexes et adaptées à l’analyse temps-fréquence ; et les ondelettes de Meyer (Meyer, 1990), à décroissance rapide en fréquence. Le choix dépend du compromis recherché entre localisation spatiale, localisation fréquentielle et coût de calcul.

20. Les moments statistiques d’une distribution mesurent sa forme. Le moment d’ordre 1 est la moyenne (position du barycentre) ; les moments d’ordre 2 sont les variances le long des axes horizontal et vertical, qui mesurent à quel point les valeurs de pixel sont étalées le long de chaque axe. Un moment d’ordre 2 élevé indique une information visuelle distribuée sur toute la dimension considérée ; un moment faible indique une concentration centrale.

21. Pour chaque pixel, on compare sa valeur à celles de ses huit voisins immédiats et l’on encode le résultat sous forme d’un nombre binaire à huit bits (1 si le voisin est plus clair, 0 sinon). La distribution de ces nombres binaires sur l’ensemble de l’image constitue le descripteur LBP. Sa principale qualité est sa robustesse aux variations d’éclairage uniformes.

22. L’image est découpée en cellules dans lesquelles on calcule, pour chaque pixel, la direction et la magnitude du gradient. Les directions sont accumulées en histogrammes par cellule, puis ces histogrammes sont concaténés pour former un descripteur compact, particulièrement utile pour la détection de formes et de contours orientés.

23. Les opérateurs de Sobel et Prewitt sont des filtres convolutifs de petite taille (typiquement 3×3) qui approximent la dérivée locale de l’image en deux dimensions ; ils mettent en évidence les variations brusques d’intensité, c’est-à-dire les contours. Plus simples et plus rapides que Canny, ils produisent un gradient brut sans étape de suppression du bruit ni de seuillage adaptatif.

24. L’algorithme de Canny enchaîne quatre étapes : un lissage gaussien pour atténuer le bruit, un calcul de la dérivée locale de l’image en deux dimensions (le ‘gradient’, qui détecte les variations brusques d’intensité), une suppression des points qui ne sont pas des maxima locaux du gradient (afin de réduire chaque contour épais à une ligne d’un pixel) et un seuillage à deux valeurs (un contour fort relie les pixels qui dépassent le seuil haut ; les pixels intermédiaires ne sont conservés que s’ils sont connectés à un contour fort).

25. Le jerk est la dérivée temporelle de l’accélération, soit le ‘taux de changement d’accélération’. Dans l’étude du geste manuel, un mouvement faible en jerk correspond à un geste fluide et bien planifié ; un mouvement riche en jerk traduit des saccades, des hésitations ou des tremblements. Cette mesure, centrale en neurologie du mouvement, peut être estimée a posteriori à partir du trait laissé sur le papier dans une certaine mesure.

26. L’entropie d’ordre 2 est étroitement liée à l’information mutuelle locale : si deux pixels voisins varient indépendamment l’un de l’autre, l’entropie d’ordre 2 est égale à deux fois l’entropie d’ordre 1 ; si leurs valeurs sont fortement corrélées (image régulière), l’entropie d’ordre 2 est plus faible que cette somme, et la différence mesure l’information qu’un pixel apporte sur son voisin.

27. La distance de Jensen-Shannon mesure la dissemblance entre deux distributions de probabilité ; elle vaut 0 si les distributions sont identiques et tend vers une valeur maximale lorsqu’elles sont totalement disjointes. Ici, on mesure à quel point la distribution observée s’écarte de la distribution complètement uniforme (l’aléatoire pur).

28. La complexité de Kolmogorov est définie indépendamment du langage de programmation : à une constante près qui ne dépend pas de l’image, sa valeur est la même que l’on choisisse un programme en Python, en C ou en machine de Turing. C’est cette indépendance qui en fait une notion mathématiquement bien définie.

29. La naissance (birth) d’une structure est la valeur du seuil ε à laquelle elle apparaît pour la première fois dans la filtration ; sa mort (death) est la valeur $\varepsilon' > \varepsilon$ à laquelle elle est absorbée par une structure plus grande ou disparaît. La différence $\varepsilon' - \varepsilon$ est sa persistance. Les structures persistantes (longue durée de vie) reflètent des organisations robustes de l’image ; les structures de courte persistance correspondent généralement au bruit.

30. Les images et paysages de persistance sont deux manières de transformer un diagramme de persistance (par nature non-vectoriel) en un vecteur de taille fixe, compatible avec les algorithmes d’apprentissage automatique. L’image de persistance représente le diagramme comme une carte de densité dans un plan ; le paysage de persistance le traduit en une famille de fonctions par morceaux ordonnées par persistance décroissante.

31. La modularité d’un découpage de graphe est la différence entre la densité d’arêtes à l’intérieur des sous-groupes proposés et celle qu’on observerait dans un graphe aléatoire de même taille. L’algorithme de Louvain ajuste itérativement le découpage pour maximiser cette modularité. C’est aujourd’hui l’algorithme de détection de communautés le plus utilisé sur les grands réseaux, pour sa rapidité et la qualité de ses partitions.

32. Dans un réseau de neurones sur graphes, chaque nœud porte un vecteur de caractéristiques qui est mis à jour à chaque couche en agrégeant les vecteurs de ses voisins immédiats. Après plusieurs couches d’agrégation, chaque nœud encode l’information de son voisinage à plusieurs sauts, ce qui permet au modèle de tenir compte de la structure relationnelle pour classifier ou regrouper.

33. La matrice de Gram d’un ensemble de vecteurs est le tableau de tous leurs produits scalaires deux à deux. Dans le contexte des CNN, on la calcule sur les activations d’une couche en traitant chaque feature map (carte produite par un filtre) comme un vecteur : la matrice obtenue mesure les corrélations entre filtres indépendamment de leur position spatiale. C’est précisément cette absence de localisation qui en fait un descripteur de style et non de contenu.

34. ResNet introduit des connexions résiduelles : chaque bloc du réseau apprend non pas la transformation complète f(x) du signal d’entrée x, mais l’écart f(x) − x. Cette astuce architecturale permet d’entraîner des réseaux beaucoup plus profonds (jusqu’à plusieurs centaines de couches) en stabilisant la propagation du gradient pendant l’apprentissage.

35. Le mécanisme d’attention (Vaswani et al., 2017) calcule, pour chaque élément d’une séquence : mot d’une phrase, patch d’image, un score d’affinité avec tous les autres éléments. Ces scores, normalisés, déterminent quels autres éléments le modèle prend en compte pour traiter celui-là. C’est ce mécanisme qui permet aux Transformers de capter des relations à longue distance dans une image, là où les CNN ne combinent que des informations spatialement voisines.

36. Littéralement transfert d’apprentissage. Le terme français existe mais l’usage anglais reste dominant dans la littérature francophone. Le principe est de tirer parti des représentations visuelles génériques apprises par un modèle sur un très grand corpus (typiquement des images photographiques courantes) pour résoudre un nouveau problème, en n’ayant à ajuster que les dernières couches du modèle avec un petit nombre d’exemples spécifiques. Cette stratégie réduit considérablement les besoins en données d’entraînement mais transfère aussi les biais du corpus initial.

37. ImageNet (Deng et al., 2009) est une base de données de plus de quatorze millions d’images photographiques étiquetées manuellement selon une taxonomie de plus de 20 000 catégories d’objets. La compétition annuelle ILSVRC organisée sur un sous-ensemble de cette base a été le moteur principal du développement des CNN entre 2012 et 2017.

38. La valeur de Shapley est issue de la théorie des jeux coopératifs (Shapley, 1953). Elle répartit équitablement le gain d’un jeu entre plusieurs joueurs en fonction de leur contribution marginale moyenne, calculée sur toutes les manières possibles d’ajouter ce joueur à un sous-groupe préexistant. Appliquée à un modèle prédictif, chaque caractéristique de l’image joue le rôle d’un joueur, et sa valeur de Shapley mesure sa contribution moyenne à la prédiction.

39. L’augmentation de données consiste à enrichir artificiellement le corpus d’entraînement en générant des variantes des images originales (rotations, recadrages, ajustements de couleurs, ajouts de bruit, retournements miroir). Ces variantes obligent le modèle à apprendre des caractéristiques invariantes aux transformations appliquées et améliorent sa capacité de généralisation à des images nouvelles.

40. Un exemple adversarial est une image légèrement perturbée, d’une quantité imperceptible à l’œil humain, qui fait basculer la prédiction du modèle vers une catégorie erronée. Goodfellow, Shlens et Szegedy (2015) ont introduit la méthode FGSM (Fast Gradient Sign Method) qui produit ces perturbations en suivant le gradient de la fonction de perte. La résistance d’un modèle à de telles perturbations mesure sa robustesse.

41. En IA générative, on parle d’hallucination lorsqu’un modèle de langage produit avec aplomb une information fausse : un nom d’auteur attribué à tort à une œuvre, une référence bibliographique fabriquée, une description d’un élément absent de l’image. Le phénomène est inhérent au mode de production statistique des modèles et concerne, même sur les modèles à l’état de l’art, un pourcentage non négligeable des réponses.

42. L’algorithme k-means partitionne un ensemble de points en k groupes (k étant choisi à l’avance) par itération de deux étapes : (1) assigner chaque point au centre de groupe le plus proche ; (2) recalculer chaque centre comme la moyenne des points qui lui sont assignés. La méthode converge vers un optimum local de la

distance intra-groupe en quelques itérations.

43. Un groupe dense est un ensemble de points qui sont mutuellement proches dans l'espace des descripteurs, en comparaison avec la densité environnante. Concrètement, HDBSCAN identifie des zones où la concentration de points est significativement plus élevée que la moyenne ; les points isolés dans des zones peu peuplées sont signalés comme aberrants plutôt que rattachés de force à un groupe.

44. t-SNE modélise les similarités entre points par des distributions de probabilité (gaussiennes dans l'espace d'origine, t de Student dans la projection) et ajuste les positions projetées pour rendre ces distributions aussi proches que possible. UMAP repose de son côté sur une formalisation de la structure de voisinage par la théorie des variétés ; il produit des projections comparables à t-SNE mais plus rapides et préserve un peu mieux la structure globale du nuage de points.

45. Le traitement automatique des langues (TAL ; Natural Language Processing ou NLP en anglais) regroupe les méthodes informatiques d'analyse et de génération de texte : extraction d'entités nommées, classification thématique, résumé automatique, traduction, et plus largement toute manipulation algorithmique d'énoncés en langue naturelle.

46. En cladistique, une synapomorphie est un caractère dérivé partagé par deux objets ou plus, hérité d'un ancêtre commun mais absent des ancêtres plus éloignés. C'est sur la distribution de ces caractères que repose la reconstruction des arbres : deux objets partageant de nombreuses synapomorphies sont considérés comme apparentés.

47. PAUP (Phylogenetic Analysis Using Parsimony) est l'un des logiciels les plus utilisés pour les reconstructions phylogénétiques par maximum de parcimonie ; il offre également des fonctions de Neighbor-Joining et d'inférence bayésienne, ainsi que des outils de bootstrap intégrés.

48. L'algorithme Neighbor-Joining (Saitou et Nei, 1987) construit un arbre en regroupant itérativement les paires d'objets dont la distance corrigée est la plus faible. Très rapide, il est largement utilisé en phylogénétique moléculaire et constitue une alternative efficace aux méthodes par parcimonie maximale, plus coûteuses en calcul.

49. La split decomposition (Bandelt et Dress, 1992) généralise la notion d'arbre à celle de réseau phylogénétique, dans lequel un nœud peut avoir plusieurs ancêtres immédiats. Cette représentation est particulièrement adaptée aux traditions évolutives non strictement arborescentes, par exemple les traditions manuscrites où un copiste consulte plusieurs sources, ou les influences artistiques croisées entre courants.

50. Le bootstrap statistique (Efron, 1979) consiste à rejouer une analyse sur de nombreux sous-échantillons tirés au sort, avec remise, des données initiales. Appliqué à la phylogénétique (Felsenstein, 1985), il revient à reconstruire un grand nombre d'arbres en sous-échantillonnant les caractères ; la fréquence à laquelle une même branche apparaît dans ces arbres mesure sa robustesse. Une branche présente dans plus de 70 à 80 % des réplications est généralement considérée comme statistiquement fiable.